**PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA DE CONTROLE E AUTOMAÇÃO**

**EDIMILSON PEREIRA**

# EFICIÊNCIA ENERGÉTICA: UMA ABORDAGEM COM IOT E INTELIGÊNCIA ARTIFICIAL PARA PREVISÃO DE CONSUMO

Vitória/ES

2026

EDIMILSON PEREIRA

# EFICIÊNCIA ENERGÉTICA: UMA ABORDAGEM COM IOT E INTELIGÊNCIA ARTIFICIAL PARA PREVISÃO DE CONSUMO

Dissertação apresentada ao Programa de Pós-graduação em Engenharia de Controle e Automação do Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo, Edimilson Pereira, como requisito parcial para a obtenção do título de Mestre em Engenharia de Controle e Automação.

Prof. Dr. Reginaldo Barbosa Nunes
Orientador

Prof. Dr. Roberto Felipe Andrade Menezes
Coorientadora

Edimilson Pereira
Aluno

Vitória/ES

2026

Dados Internacionais de Catalogação-na-Publicação (CIP)
(Biblioteca Nilo Peçanha do Instituto Federal do Espírito Santo)

X999y

EFICIÊNCIA ENERGÉTICA: UMA ABORDAGEM COM IOT E INTELIGÊNCIA ARTIFICIAL PARA PREVISÃO DE CONSUMO/ Edimilson Pereira. – 2026.

97 f: il; 30 cm.

Orientador: Reginaldo Barbosa Nunes

– Instituto Federal do Espírito Santo, PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA DE CONTROLE E AUTOMAÇÃO, 2026.

1. Inteligência Artificial. 2. Eficiência Energética. 3. Internet das Coisas. 4. Redes Neurais Recorrentes . I. PEREIRA, EDIMILSON. II. Instituto Federal do Espírito Santo. III. EFICIÊNCIA ENERGÉTICA: UMA ABORDAGEM COM IOT E INTELIGÊNCIA ARTIFICIAL PARA PREVISÃO DE CONSUMO.

CDD 000.00

Elaborada por XXXXXXXXXXXXXXXXXXXXX – CRB-X/ES - XXX

À memória da minha Avô,Lala, *in memoriam*,
que mesmo ausente, cuidou de nos quando meu pai me abandonou..
À minha mãe, Laura, pela insistência e motivação todos os dias para persistir e dedicar nos estudos .
À minha esposa, Lorraine,pela paciência, cuidado e motivação todos os dias e incentivação ao não desistir.
À minha filha, Heloisa ,pelo carinho e dedicação e todos os dias dizer para papai que tudo ia dar certor.
Este trabalho é o fruto que colhemos juntos em família e amigos.

## AGRADECIMENTOS

A Deus, pela saúde, força e sabedoria que me sustentaram durante todo o percurso deste mestrado.

Aos meus colegas professores, pela amizade, incentivo e troca constante de conhecimentos, que enriqueceram esta caminhada acadêmica.

Aos mestres e orientadores, pela dedicação, paciência e contribuição essencial para o meu crescimento científico e profissional.

A todos que, de maneira direta ou indireta, colaboraram com este trabalho — colegas de turma, familiares e amigos — deixo meu sincero agradecimento pelo apoio e confiança.

**“Os dias prósperos não vêm por acaso; nascem de muita fadiga e persistência.”**

Henry Ford

## RESUMO

A eficiência energética é uma exigência cada vez mais presente na humanidade em que vivemos, com postura mais consciente do consumo da eletricidade na educação. A ausência de sistemas de monitoramento e as dificuldades de identificação de desperdícios são fatores que impactam diretamente a pegada ambiental, exigindo soluções tecnológicas alinhadas à sustentabilidade e à Indústria 4.0. Este trabalho busca o desenvolvimento de um sistema inteligente de baixo custo, baseado em Internet das Coisas (IoT) e Inteligência Artificial (IA), para previsão e monitoramento do consumo energético em tempo real. Dados de consumo como tensão, corrente e potência coletados pelo sensor PZEM-004t conectado ao microcontrolador ESP32, serão armazenados em banco de dados FIREBASE na nuvem e analisados por uma Rede Neural Recorrente (RNN) LSTM e pelo modelo estatístico ARIMA, permitindo identificar padrões de consumo, prever demandas e sugerir estratégias de otimização.

A pesquisa é de caráter experimental e quantitativo, inclui prototipação, coleta, pré-processamento, além da implementação de um dashboard interativo para visualização em tempo real. Espera-se com este trabalho demonstrar reduções significativas no consumo energético, aumento da eficiência operacional e maior sustentabilidade, evidenciando como a integração entre IoT e IA pode transformar a eficiência energética.



**Palavras-chave:** Inteligência Artificial. Internet das Coisas. Sustentabilidade. Eficiência Energética. Redes Neurais Recorrentes . ARIMA.

## ABSTRACT

Energy efficiency is an increasingly critical demand in modern society, calling for a more conscious approach to electricity consumption within educational settings. The lack of monitoring systems and the difficulty in identifying waste are factors that directly impact the environmental footprint, requiring technological solutions aligned with sustainability and Industry 4.0. This study aims to develop a low-cost intelligent system based on the Internet of Things (IoT) and Artificial Intelligence (AI) for real-time energy consumption monitoring and forecasting. Consumption data—such as voltage, current, and power—collected by the PZEM-004T sensor connected to an ESP32 microcontroller, are stored in a Firebase cloud database. This data is analyzed using a Long Short-Term Memory (LSTM) Recurrent Neural Network and the ARIMA statistical model to identify consumption patterns, forecast demand, and suggest optimization strategies.

The research is experimental and quantitative, encompassing prototyping, data collection, pre-processing, and the implementation of an interactive dashboard for real-time visualization. This work expects to demonstrate significant reductions in energy consumption, increased operational efficiency, and enhanced sustainability, highlighting how the integration of IoT and AI can transform energy management.



**Key Words:** Artificial Intelligence. Internet of Things. Sustainability. Energy Efficiency. Recurrent Neural Networks . ARIMA.

## LISTA DE ILUSTRAÇÕES


Figura 1 – Vista de satélite do Campus Vitória - ES . . . . . 16
Figura 2 – Fluxograma do processo metodológico . . . . . 19
Figura 3 – Gráfico da participação de energias renováveis na matriz (2015–2024) 28
Figura 4 – Geração de energia elétrica por fonte (2024) . . . . . 29
Figura 5 – consumo de energia elétrica por setor (2024) . . . . . 30
Figura 6 – Etiqueta de eficiência energética . . . . . 31
Figura 7 – Programas e legislações que tratam de sustentabilidade em IESF . 32
Figura 8 – Teste de Turing: experimento que identifica se IA superou humanos. 33
Figura 9 – Como é o treinamento do algoritmo para identificar e classificar os spams . . . . . 35
Figura 10 – Estrutura de uma Random Forest . . . . . 36
Figura 11 – Componentes de um modelo ARIMA(p, d, q). . . . . 37
Figura 12 – Neurônio Artificial(Perceptron). . . . . 37
Figura 13 – Redes Neurais Multicamadas. . . . . 38
Figura 14 – Exemplo de classificação com rede neural. “Cachorro” . . . . . 38
Figura 15 – Diagrama de uma Rede Neural Recorrente compacta e sua estrutura expandida no tempo. . . . . 39
Figura 16 – Arquitetura interna de uma célula LSTM e seus mecanismos de portões (gates) . . . . . 40
Figura 17 – Internet das Coisas: Conceitos e Aplicações . . . . . 41
Figura 18 – Diagrama de blocos do sistema inteligente de monitoramento energético. . . . . 44
Figura 19 – Fluxograma geral de funcionamento do sistema. . . . . 46
Figura 20 – Descrição resumida dos componentes e suas respectivas funções. . 47
Figura 21 – Pzem-004T. . . . . 49
Figura 22 – Bobina toroidal Clamp Monitor PZCT-02 100A. . . . . 49
Figura 23 – NodeMCU ESP32 (DevKit WROOM-32). . . . . 50
Figura 24 – Esquema de disposição das conexoes do NodeMCU ESP32 . . . . . 51
Figura 25 – Visor LCD 16x2 Alfanumérico HD44780. . . . . 52
Figura 26 – Roteador wireless TP-Link TL-WR849N . . . . . 53
Figura 27 – Logotipo da plataforma Firebase (Google). . . . . 54

Figura 28 – Estrutura de dados em árvore JSON no Realtime Database. . . . . 55
Figura 29 – Comunicação entre PZEM-004T para ESP32. . . . . 56
Figura 30 – Diagrama elétrico de Conexão Módulo I2C e o ESP32. . . . . 57
Figura 31 – trecho do código do visor na parte das bibliotecas. . . . . 58
Figura 32 – Foto do visor com interface de feedback. . . . . 58
Figura 33 – Diagrama de instalação elétrica e IoT. . . . . 59
Figura 34 – Foto do Protótipo e instrumentação pronta. . . . . 60
Figura 35 – caixa hermética vedada Ip68 250x200x130mm. . . . . 61
Figura 36 – Projeto Firebase consumo-conciente. . . . . 61
Figura 37 – Estrutura JSON da tabala leituras . . . . . 62
Figura 38 – Token de autenticação database secret firebase. . . . . 63
Figura 39 – processos de leitura a cada 15 minuto de teste de bancada. . . . . 65
Figura 40 – Testes de coletas iniciais de bancada residencial. . . . . 65
Figura 41 – Recorte do dataset de bancada gerado no Firebase. . . . . 68
Figura 42 – Arquitetura de fluxo e pipeline de dados do sistema integrado. . . . 69
Figura 43 – Árvore hierárquica de diretórios do projeto integrado. . . . . 75
Figura 44 – Interface gráfica do dashboard com os indicadores e o comparativo gráfico de consumo real e previsto . . . . . 77
Figura 45 – Comportamento dinâmico da interface web operando sob regime de detecção de anomalia na rede de distribuição elétrica . . . . . 78
Figura 46 – diagrama de blocos de fluxo de dados ou organograma do pipeline do Flask . . . . . 79
Figura 47 – Estrutura do payload em formato JSON retornado pelas rotas da API para consumo do cliente web. . . . . 81
Figura 48 – Gráfico da Evolução das Métricas pelo Horizonte de Previsão . . . . 86
Figura 49 – Curva comparativa científica de consumo real versus previsões do modelo LSTM e ARIMA. . . . . 86
Figura 50 – Interface do Dashboard Web em pleno funcionamento e visualização de telemetrias. . . . . 87

## LISTA DE TABELAS

Tabela 1 – Resumo quantitativo das amostras do dataset. . . . . 67
Tabela 2 – Matriz comparativa de desempenho preditivo por horizonte temporal. 83
Tabela 3 – Matriz de avaliação e métricas de erro estatístico para múltiplos horizontes preditivos . . . . . 85

## LISTA DE QUADROS

Quadro 1 – Exemplos da definição de eficiência energética ao longo das décadas. 26
Quadro 2 – Trabalhos relacionados apresentados . . . . . 27
Quadro 3 – Oito definições de IA . . . . . 34
Quadro 4 – Esquema de pinagem PZEM-004T para ESP32. . . . . 56
Quadro 5 – Estrutura de diretórios e componentes de software do projeto. . . . 70
Quadro 6 – Catálogo de rotas da API Flask e especificações de retorno do servidor. . . . . 80

## LISTA DE SIGLAS

| | |
|---|---|
| IFES | Instituto Federal do Espírito Santo |
| IA | Inteligência Artificial |
| RNN | Redes Neurais Recorrentes |
| IOT | Internet of Things |
| ARIMA | Autoregressive Integrated Moving Average |
| LSTM | Long Short-Term Memory |

## LISTA DE SÍMBOLOS

| | |
|---|---|
| $\lambda$ | Letra grega labda |

**SUMÁRIO**


**1 INTRODUÇÃO . . . . . 16**
1.1 OBJETIVOS . . . . . 18
**1.1.1 Objetivo Geral . . . . . 18**
**1.1.2 Objetivos Específicos . . . . . 18**
1.2 METODOLOGIA . . . . . 19
1.3 ORGANIZAÇÃO DA DISSERTAÇÃO . . . . . 24
**2 FUNDAMENTAÇÃO TEÓRICA . . . . . 25**
2.1 CONCEITOS E DEFINIÇÕES EFICIÊNCIA ENERGÉTICAS . . . . . 25
**2.1.1 CONSUMO DE ENERGIA NO BRASIL . . . . . 28**
**2.1.2 EFICIÊNCIA ENERGÉTICA NAS INSTITUIÇÕES PÚBLICAS DE ENSINO . . . . . 31**
2.2 INTELIGÊNCIA ARTIFICIAL . . . . . 33
2.3 MACHINE LEARNING (APRENDIZADO DE MÁQUINA) . . . . . 34
2.4 ALGORITMO RANDOM FOREST . . . . . 36
2.5 MODELO ARIMA . . . . . 36
2.6 REDES NEURAIS . . . . . 37
2.7 REDES NEURAIS RECORRENTES . . . . . 38
**2.7.1 REDE NEURAL RECORRENTE LSTM (LONG SHORT-TERM MEMORY) . . . . . 40**
2.8 IOT . . . . . 41
2.9 CONCLUSÃO . . . . . 42
**3 DESENVOLVIMENTO . . . . . 43**
3.1 ARQUITETURA DO SISTEMA E FLUXO DE DADOS . . . . . 43
**3.1.1 Módulo de Coleta de Dados . . . . . 44**
**3.1.2 Módulo de Transmissão de Dados . . . . . 44**
**3.1.3 Módulo de Análise Inteligente . . . . . 45**
**3.1.4 Módulo de Visualização de Resultados . . . . . 45**
**3.1.5 Fluxo Geral do Sistema . . . . . 46**
3.2 MATERIAIS E MÉTODOS . . . . . 47
3.3 DESCRIÇÃO DO HARDWARE E PLATAFORMA DE COMUNICAÇÃO 48
**3.3.1 MODULO PZEM-004T . . . . . 48**

**3.3.2 Microcontrolador ESP32 (Inteligência de Borda) . . . . . 50**
**3.3.3 Visor LCD Alfanumérico HD44780 (Interface Local) . . . . . 51**
**3.3.4 Infraestrutura de Rede: Roteador Wireless TL-WR849N . . . . . 52**
**3.3.5 Plataforma de Dados: Firebase Realtime Database . . . . . 53**
3.4 INSTRUMENTAÇÃO IOT E COLETA DE DADOS . . . . . 55
**3.4.1 Interface de Comunicação PZEM-004T para ESP32 . . . . . 55**
**3.4.2 Montagem do Visor LCD com Módulo I2C no ESP32. . . . . 56**
**3.4.3 Configuração de Software e Instrumentação . . . . . 57**
**3.4.4 Condicionamento e Montagem dos componentes do protótipo . 59**
**3.4.5 Implementação e Estrutura do Banco de Dados Firebase . . . . . 61**
**3.4.6 Implementação Técnica . . . . . 63**
3.5 ETAPA DE COLETA DE DADOS . . . . . 64
**3.5.1 Ambiente de Testes e Validação . . . . . 64**
**3.5.2 Dataset de Consumo Residencial de bancada . . . . . 64**
**3.5.3 Banco de dados do consumo gerado na bancada de testes . . . 66**
**3.5.4 Granularidade e Volume . . . . . 66**
**3.5.5 Estrutura do Dataset de 30 Dias . . . . . 67**
3.6 ARQUITETURA GERAL DO ECOSSISTEMA DE MONITORAMENTO 68
**3.6.1 Ferramentas Computacionais e Organização Estrutural do Software 70**
**3.6.2 Camada de Persistência e Ingestão de Dados em Tempo Real . . 70**
**3.6.3 Pipeline de Pré-processamento e Tratamento dos Dados . . . . . 71**
**3.6.4 Modelagem Preditiva Baseada em Inteligência Artificial . . . . . 72**
**3.6.5 Modelo 1: Rede Neural Profunda LSTM (Long Short-Term Memory) 72**
**3.6.6 Modelo 2: ARIMA (Autoregressive Integrated Moving Average) . 73**
**3.6.7 Horizontes de Previsão Avaliados (Multi-Step Forecasting) . . . 73**
**3.6.8 Protocolo de Validação e Métricas de Desempenho . . . . . 73**
**3.6.9 Organização Estrutural e Arquitetura de Diretórios do Projeto . . 74**
3.7 DASHBOARD E INTEGRAÇÃO BACK-END . . . . . 75
**3.7.1 Desenvolvimento do Dashboard e Integração do Flask-Firebase. 75**
**3.7.2 Estrutura e Indicadores do Dashboard . . . . . 76**
**3.7.3 Fluxo de Dados e Pipeline do Back-end . . . . . 78**
**3.7.4 Especificação das Rotas da API REST . . . . . 80**

**4 RESULTADOS E DISCUSSÃO . . . . . 82**
**4.0.1 Parametrização dos Modelos e Protocolo de Validação . . . . . 82**
**4.0.2 Análise de Desempenho Comparativa: Lstm × Arima . . . . . 84**
**4.0.3 Validação Prática e Acompanhamento Contra Dados Reais . . . 86**
**4.0.4 Avaliação da Interface Operacional do Dashboard e Detecção de Anomalias . . . . . 87**
**4.0.5 Conclusão Entre Modelos LSTM e ARIMA . . . . . 87**
**5 CONCLUSÃO . . . . . 89**
**REFERÊNCIAS . . . . . 90**

# 1 INTRODUÇÃO

Nas últimas décadas, a eficiência energética consolidou-se como um pilar estratégico das políticas públicas globais, impulsionada pela urgência em mitigar danos ambientais e promover modelos econômicos resilientes (LEAD ENERGIA, 2024). Segundo Carvalho (2019), o desenvolvimento sustentável depende do equilíbrio entre preservação ecossistêmica, equidade social e viabilidade econômica, dimensões interdependentes que exigem soluções integradas. No Brasil, o setor educacional apresenta um perfil de consumo crítico; dados da ANEEL (2024) indicam que instituições de ensino demandam, em média, 7.000 kWh mensais.

Figura 1 – Vista de satélite do Campus Vitória - ES

Fonte:Google Maps (2026).

Neste cenário, destaca-se o Instituto Federal do Espírito Santo (IFES), instituição de referência que integra ensino, pesquisa e extensão demostrado na Figura 1. O Campus Vitória, unidade mais antiga e complexa da instituição, possui trajetória histórica iniciada em 1909 como escola de aprendizes artífices, evoluindo até sua configuração atual em 2008. Localizado em Jucutuquara, o campus atende desde o ensino técnico até o doutorado, apresentando a maior comunidade acadêmica do instituto, com cerca de 4.000 discentes e 300 docentes.

A infraestrutura para suportar essa magnitude inclui dezenas de laboratórios especializados, oficinas mecânicas, ginásios e setores administrativos. O uso intensivo

de maquinário industrial e sistemas de climatização em larga escala resulta em uma demanda energética contínua e elevada, com faturas substancialmente superiores às de unidades menores. Assim, ações de eficiência energética são imprescindíveis para viabilizar objetivos econômicos e socioambientais em uma estrutura de tal porte. Diante do exposto, define-se o problema de pesquisa: Como reduzir o consumo energético do IFES Campus Vitória aplicando ações de eficiência energética?

Como resposta a esse desafio, as inovações da Indústria 4.0 surgem como aliadas estratégicas. A implementação de sensores baseados em Internet das Coisas (IoT) permite o monitoramento preciso e em tempo real, enquanto a Inteligência Artificial (IA) viabiliza a identificação de padrões e a otimização de fluxos. Estimativas indicam que a adoção dessas tecnologias pode reduzir o gasto energético entre 5% e 20%.

Este trabalho propõe, portanto, o desenvolvimento de um ecossistema inteligente que une IoT e IA para refinar a gestão de recursos energéticos no âmbito educacional. O intuito é evidenciar como a integração de dados e a conectividade podem transformar a eficiência do setor, promovendo uma operação sustentável e adaptada aos novos paradigmas tecnológicos.

## 1.1 OBJETIVOS

### 1.1.1 Objetivo Geral

Desenvolver um sistema inteligente de baixo custo, baseado em (IoT) e (IA) para promover a eficiência energética e a sustentabilidade em instituições de ensino, por meio da previsão e monitoramento em tempo real do consumo de energia.

### 1.1.2 Objetivos Específicos

1. Construir um protótipo de medidor de consumo instantâneo de energia com sensores IoT em um hardware embarcado para coleta de consumo.
2. Gerar um banco de dados sobre o consumo em campo com o protótipo em bancada de testes.
3. Implementar o protótipo de medidor de consumo para coleta de dados em um ambiente de instituição educacional.
4. Gerar dados do consumo instantâneo de energia no ambiente educacional.
5. Realizar as previsões utilizando a LSTM e o modelo de ARIMA.
6. Criar uma Dashboard com os dados de consumo em tempo real via rede Wi-fi.
7. Avaliar os resultados e sugerir a redução de custos energéticos no ambiente analisado.

## 1.2 METODOLOGIA

A presente pesquisa possui caráter experimental, com foco no desenvolvimento, implementação e validação de um Sistema de Gestão Inteligente para Otimização do Consumo Energético, fundamentado na integração entre Internet das Coisas (IoT) e Inteligência Artificial (IA), aplicado ao contexto do Instituto Federal do Espírito Santo (IFES).

A metodologia foi estruturada em etapas sequenciais e interdependentes como e demostrado no fluxograma dos processos metodológicos na Figura 2, definidas a partir dos objetivos geral e específicos, de modo a garantir rigor científico, reprodutibilidade dos experimentos e viabilidade de aplicação em ambientes reais. O processo metodológico contempla desde a prototipação de hardware a coleta de dados em tempo real e a modelagem de previsões de modelos de IA com visualização dos resultados.

Figura 2 – Fluxograma do processo metodológico

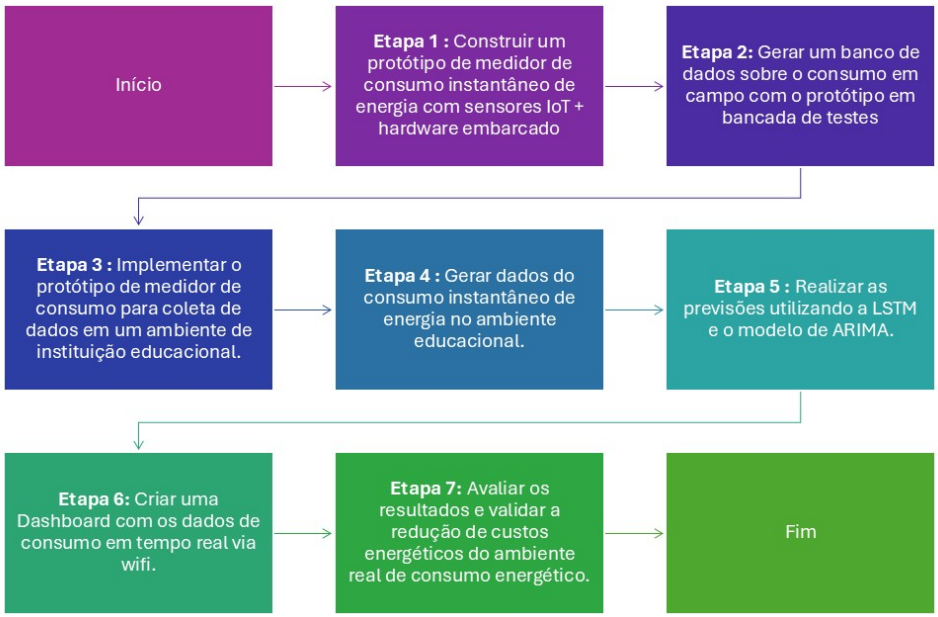


Fonte: Elaboração do próprio autor (2026).

**Etapa 1 – Construção do protótipo do medidor de consumo**

Nesta etapa inicial, será construido um protótipo de medidor de consumo instantâneo de energia com sensores IoT + hardware embarcado, serão utilizados:

- Modulo de medição de tensão, corrente e potência PZEM- 004T.
- Clamp Monitor PZCT-02 100A.
- Microcontrolador ESP32, para leitura dos dados elétricos de consumo.
- Visor LCD Alfanumérico HD44780 que servira como sistema de monitoramento de campo com Interface Local.
- Roteador Wireless 300mbps Wi-Fi TL-WR 849n Tp-link.
- Caixa Plástica Pvc Multiuso Ip66 Tampa Transp 190x150x90mm.

Os códigos embarcados foi desenvolvido em C++ no ESP32, responsável por realizar a leitura dos sinais analógicos provenientes do modulo de medição de tensão, corrente e potência PZEM-004T que processa as medições localmente e transmite via Wi-fi em um roteador conectado ao internet para Banco de dados Firebase, A comunicação utilizada pelo Wi-Fi é a biblioteca <WiFi.h> e a biblioteca Firebase-ESP-Client para trocar dados em tempo real via formato (JSON) com o Realtime Database, realizando a autenticação via API Key/Database Secret. Essa etapa culmina na montagem e funcionamento do protótipo do sistema inteligente de monitoramento energético.

**Etapa 2 – Construção e geração do dataset de consumo de bancada**

Inicialmente, realizamos a construção de um dataset com os dados das leituras realizadas inicialmente com o protótipo em bancada de testes, o dataset sera feito no firebase realtime para regulagem e calibragem das variáveis como: consumo, corrente, potência e voltagem do dataset consumo-consciente energético de bancada. Essa etapa visa compreender o comportamento e funcionamento inicias do sistema e também subsidiar o desenvolvimento inicial dos modelos inteligentes. Os dados do dataset passarão por um processo de pré-processamento, que inclui:

- limpeza e tratamento de valores ausentes ou inconsistentes;
- normalização e padronização das variáveis;

O resultado desta etapa será um dataset consumo-consciente energético de bancada, pronto para análise e modelagem.

**Etapa 3 – Implementação do protótipo no ambiente do Ifes Campus Vitoria**

Nesta etapa foi Implementado e configurado o protótipo de medidor de consumo para coleta de dados em um ambiente real do campus IFES Vitória no Laboratório de elétrica para leitura do consumo instantâneo de energia com sensores IoT + hardware embarcado, instalado no quadro de disjuntor do bloco de laboratórios. Serão utilizados:

- Protótipo do Sistema de consumo organizado em uma caixa transparente.
- Roteador Wireless 300mbps Wi-Fi TL-WR 849n Tp-link.
- Disjuntor Unipolar 20A.
- Rede Wi-fi disponível para acesso e conexões dos dispositivos IOT.

**Etapa 4 – Geração do dataset de consumo do ambiente real da instituição educacional**

Construção de um dataset com os dados das leituras com o prototipo em funciomanento no Campus Vitoria, ja calibrado e configurado as variaveis necessarias. Essa etapa visa gerar dados de consumo instantaneo em um tempo maior de leitura, para ter uma big data do consumo do campus, para utilização da proxima etapa de modelagem e avalição dos algoritmos de IA. O resultado desta etapa será um dataset energético do consumo do campus, pronto para análise e modelagem.

**Etapa 5 – Modelagem e Previsões dos modelos de algoritmo de IA**

Com os dados normalizados, foram desenvolvido e treinado os dois modelos distintos:

- ARIMA, para modelagem temporal e previsão de séries históricas de consumo;
- Rede Neural Recorrente (RNN) LSTM.

Os modelos foram implementados em ambiente Google Colab, permitindo reprodutibilidade e documentação clara dos experimentos. O desempenho dos algoritmos será avaliado por métricas estatísticas apropriadas, como erro médio absoluto (MAE), erro quadrático médio (MSE) e coeficiente de determinação ($R^2$), além da análise gráfica comparativa. Essa etapa resulta na comparação objetiva entre os modelos, subsidiando a escolha da abordagem mais adequada para integração ao sistema embarcado.

**Etapa 6 – Implementação do dashboard de monitoramento**

Para visualização e apoio à tomada de decisão, foi desenvolvido um painel de controle (dashboard) com interface web responsiva, utilizando :

- Python;
- Framework Flask ;
- HTML5;
- CSS3;
- JavaScript;
- biblioteca Chart.js.

O dashboard permiti:

- monitoramento do consumo energético em tempo real;
- emissão de alertas de uso excessivo;
- visualização de previsões de gastos energéticos;
- acompanhamento da eficiência após a implementação do sistema.

**Etapa 7 – Avaliação, validação e sugestões dos custos energéticos**

Por fim, foi realizada a avaliação, validação do sistema em ambiente real, dos laboratórios do IFES (Campus Vitoria). Os dados antes e depois da implementação serão comparados, permitindo avaliar e dar sugestões de melhorias como:

- Redução de desperdícios.
- Economia de custos energéticos.
- Melhorias operacionais nos Laboratórios.
- Efetividade do modelo inteligente proposto.

Essa etapa resultou em um relatório final, contendo o dataset validado, o modelo selecionado e as análises gráficas e estatísticas do desempenho do sistema e as sugestões de redução de custos energéticos no ambiente analisado.

**Conclusão**

A metodologia adotada permitiu a implementação sistemática do projeto, garantindo a viabilidade técnica e científica da proposta. A combinação de IoT e IA configura uma solução inovadora para otimização do consumo energético nas instituições de ensino, promovendo maior eficiência e sustentabilidade na educação.

**Local da Pesquisa**

O projeto foi desenvolvido em parceria com o Instituto Federal do Espirito Santo - Ifes Campus Vitória, onde foram instalados os sensores e realizado o monitoramento dos processos produtivos. Além disso, testes laboratoriais preliminares foram conduzidos em ambiente residencial para calibração dos dispositivos e validação inicial dos modelos de IA e posteriormente instalados no laboratório de elétrica do campus Vitória.

## 1.3 ORGANIZAÇÃO DA DISSERTAÇÃO

Esta dissertação está organizada de forma a conduzir o leitor, de maneira clara e progressiva, desde a contextualização do tema até as conclusões e proposições para trabalhos futuros.

O Capítulo 1, apresenta a contextualização da pesquisa, destacando a relevância da eficiência energética nas instituições de ensino, o problema investigado, os objetivos geral e específicos, a justificativa, a metodologia adotada e a estrutura do trabalho.

No Capítulo 2, desenvolve-se a revisão bibliográfica, abordando os conceitos de Indústria 4.0, Internet das Coisas e Inteligência Artificial, bem como estudos relacionados à eficiência energética, ao consumo de recursos e à aplicação de técnicas de aprendizado de máquina, situando o estado da arte e as lacunas de pesquisa.

O Capítulo 3, descreve o percurso metodológico, detalhando os procedimentos técnicos, os dispositivos e sensores utilizados, as etapas de coleta e pré-processamento dos dados, as ferramentas computacionais empregadas e os modelos desenvolvidos, além das estratégias de implementação e validação do sistema proposto.

O Capítulo 4, apresenta e discute os resultados obtidos, analisando o desempenho dos modelos de aprendizado de máquina, a eficácia do sistema na otimização do consumo energético e a comparação com dados reais e estudos da literatura.

Por fim, o Capítulo 5 sintetiza as conclusões do estudo, avalia os resultados e levantar propostas para a redução de custos energéticos do ambiente estudado, aponta limitações e propõe direções para pesquisas futuras e possíveis extensões da solução desenvolvida.

# 2 FUNDAMENTAÇÃO TEÓRICA

A Indústria 4.0 integra sistemas físicos e digitais através de tecnologias como IoT e Inteligência Artificial, otimizando a autonomia e a tomada de decisão estratégica (SCHWAB, 2019); (GODOI; ARAúJO, 2019). No cerne dessa transformação, a eficiência energética surge como um imperativo, visto que a demanda global de energia projeta um crescimento superior a 50% até 2040 (BOTELHO, 2018). Diante do cenário de mudanças climáticas, a gestão energética deve superar o fornecimento básico, focando em duas vertentes principais: a econômica, pela redução de custos operacionais, e a ambiental, pela mitigação de emissões de Co2 (LLAMAS, 2009). O conceito fundamental de eficiência energética não implica em racionamento, mas na entrega do mesmo serviço ou superior com menor consumo de recursos. Assim, a aplicação de processos inteligentes e tecnologias otimizadas permite conciliar o desenvolvimento socioeconômico com a sustentabilidade ambiental, atendendo à crescente dependência da eletricidade nos sistemas de comunicação e produção contemporâneos (TESSMER, 2002). Nesse contexto, a análise e o monitoramento contínuo de dados tornaram-se essenciais para a otimização de processos educacionais, especialmente em setores intensivos em consumo de energia.

## 2.1 CONCEITOS E DEFINIÇÕES EFICIÊNCIA ENERGÉTICAS

Diante do aumento da demanda populacional por energia elétrica, o desenvolvimento de soluções voltadas ao uso racional dos recursos tornou-se imperativo. A eficiência energética surge como uma dessas alternativas, acumulando, desde a década de 1980, diversas interpretações conceituais. Conforme visto no **Quadro 1** reunimos algumas das definições mais relevantes, organizadas por autor e ano.

Quadro 1 – Exemplos da definição de eficiência energética ao longo das décadas.

| Nome do Artigo | Definição | Autor e Ano |
|---|---|---|
| Análise eco energética dos sistemas de produção da zona vitícola de Dois Portos (Torres Vedras). | A eficiência energética de um sistema é expressa pela relação producão bruta de energia /conjunto de entradas de energia. | (CARVALHO, 1980) |
| Inovação Tecnológica e Eficiência Energética | Entende-se por eficiência energética o conjunto de práticas e políticas que reduzam os custos com energia e/ou aumentem a quantidade de energia oferecida sem alteração da geração, que podem ser resumidas a seguir: Planejamento integrado dos recursos; Eficiência na Geração, Transmissão e Distribuição ; Gerenciamento pelo lado da Demanda; Eficiência no Uso Final. | (MARTINS, 1999) |
| O Efeito Estufa e o Setor Energético Brasileiro). | Esta significaria a manutenção do mesmo tipo e nível de serviços adquiridos a partir de uma quantidade menor de energia. | (GUTIERREZ; MENDONÇA, 2000) |
| Análise energética da cultura do CRAMBE (Crambe abyssinica Hochst) produzida em plantio direto | A determinação da eficiência energética é importante instrumento no monitoramento da sustentabilidade da agricultura ante o uso de fontes de energia não renováveis | (JASPER *et at.*, 2010) |
| Estudo de Caso: Avaliação dos benefícios obtidos com a implantação de práticas de sustentabilidade e de eficiência energética em edificação pública | É a obtenção dos mesmos bens e serviços energéticos, mas com muito menos energia, com a mesma o maior qualidade de vida, com menos poluição, a um preço mais baixo do que o atual prolongando a vida dos recursos. | (SANTOS *et at.*, 2019) |

Fonte: Mata, Marcelly Januário da.2021

Fundamentadas na busca pela melhoria contínua e pela mitigação do consumo excedente, diversas investigações científicas convergem para a proposição de diretrizes práticas em eficiência energética. Tais estudos transcendem a teoria ao apresentar soluções aplicáveis a diferentes contextos operacionais. Uma síntese de intervenções relevantes, extraídas da literatura recente, é apresentada no **Quadro 2**, evidenciando as principais estratégias de otimização adotadas no setor que serve como embasamento teorico e trabalhos relacionados para nosso trabalho.

Quadro 2 – Trabalhos relacionados apresentados

| Título da Pesquisa | Propostas Apresentadas | Autor e Ano |
|---|---|---|
| Avaliação da Eficácia das Politicas de Eficiência Energética do Setor Público. | Caracterizar adequadamente os edifício para melhor entendimento implementação de políticas públicas. - Alocar às políticas públicas de eficiência energética os fundos necessários à sua prossecução assim como articular os diferentes instrumentos de apoio existentes. | (RODRIGUES, 2018). |
| Indicador Eficiência Energética para Auxiliar a Tomada de Decisão de Investimento Eficiência Energética em Instituições de Ensino. | - Necessidade do desenvolvimento de projetos de Eficiência Energética. - Necessidade de investimentos nos projetos de EE. - Criação de indicadores capazes de auxiliar na tomada de decisão quanto a aplicação de um determinado projeto, para que haja um melhor aproveitamento do investimento | (RIBEIRO; SILVA, 2018). |
| Perspectiva de uso da Inteligência Artificial (IA) para Eficiên-cia Energética em Prédios Pú-blicos | - Implementação de técnicas para a melhoria no uso de energia elétrica em prédios públicos mediante a utilização da inteligência artificial. - Uso de medidores inteligentes, com controle desses equipamentos a distância, sistemas automatizados, entre outras tecnologias. | (JUSTINO; SILVA; RABELO, 2020) |
| Projeto de Eficiência Energética para Envoltória e Ilumina-ção Artificial: Estudo de Caso na Escola Politécnica de Per-nambuco. | - Aplicar medidas simples, como especificar a cor do revestimento das superfícies externas de uma edificação e pensar na sequência de acendimento do sistema de iluminação. - Buscar conhecimento de mercado, visando encontrar produtos com melhores tecnologias e mais eficientes. - Realizar a instalação da luminárias de forma que o acendimento fique paralelo as esquadrias. | (RABBANI, 2020). |

Fonte: Mata, Marcelly Januário da.2021

Em suma, a convergência entre os estudos apresentados nos quadros 1 e quadros 2 reitera que as estratégias de eficiência energética (EE) fundamentam-se na tríade: gestão otimizada de recursos, modernização tecnológica e conscientização dos usuários. A reiteração dessas ações na literatura científica não apenas valida sua eficácia, mas sublinha a necessidade imperativa de implementar programas estruturados que promovam o uso racional e sustentável da energia.

### 2.1.1 CONSUMO DE ENERGIA NO BRASIL

O Balanço Energético Nacional (BEN), elaborado anualmente pela Empresa de Pesquisa Energética (EPE), vinculada ao Ministério de Minas e Energia (MME), constitui a principal base de dados para o planejamento energético brasileiro. Essa publicação consolida informações detalhadas sobre a oferta e o consumo de energia no país, abrangendo todas as etapas do processo energético, desde a produção de fontes primárias até o consumo final. Na edição mais recente, o BEN 2025 (ano base 2024) aponta que a oferta interna de energia no Brasil atingiu aproximadamente 322 milhões de toneladas equivalentes de petróleo (Mtep), representando um crescimento de 2,4% em relação ao ano anterior.

Um aspecto relevante da matriz energética brasileira é sua elevada participação de fontes renováveis. Em 2024, o país alcançou um marco histórico, com 50% da matriz energética composta por fontes renováveis, valor significativamente superior à média mundial, comprovando o que mostra na **figura 3** o gráfico da evolução de 2015 a 2024.

Figura 3 – Gráfico da participação de energias renováveis na matriz (2015–2024)

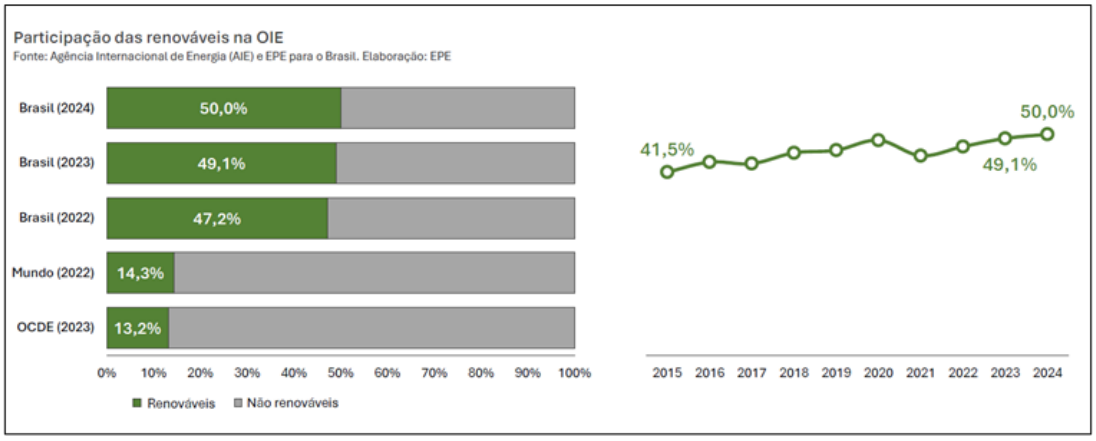


Fonte: Agência Internacional de Energia (AIE) e EPE(2025).

No que se refere à matriz elétrica, o Brasil mantém um perfil ainda mais sustentável. As fontes renováveis representaram cerca de 88% da oferta interna de eletricidade, com destaque para a energia hidráulica, responsável por aproximadamente 56,8% da geração, seguida pelo crescimento expressivo das fontes eólica e solar.

A geração total de energia elétrica no país demostrada na figura 4 através do gráfico alcançou 751,3 TWh em 2024, registrando crescimento de 6,1% em relação a 2023,

enquanto o consumo final atingiu 650,4 TWh, com expansão de 5,5%.

Figura 4 – Geração de energia elétrica por fonte (2024)

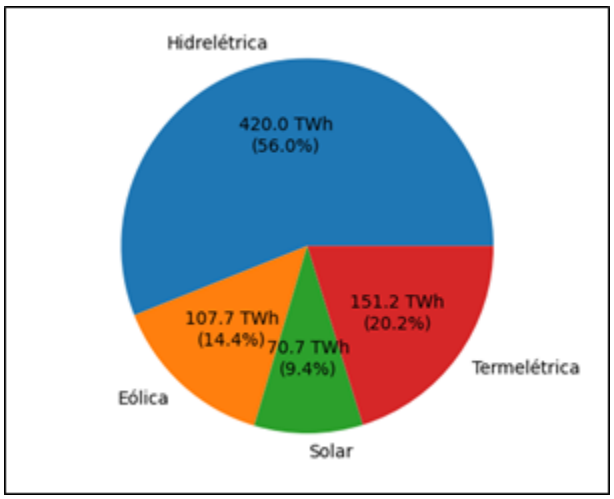


Fonte: Agência Internacional de Energia (AIE) e EPE(2025).

A demanda por energia elétrica vem aumentando consideravelmente em todo o mundo, inclusive no Brasil, em função da constante introdução de equipamentos elétricos, associada ao comportamento consumista da sociedade (SILVA, 2015). Esses fatores contribuem para a melhoria da qualidade de vida dos indivíduos e para o desenvolvimento econômico dos países; contudo, também apresentam aspectos negativos, como o risco de esgotamento dos recursos energéticos e os impactos ambientais decorrentes de sua utilização.

Segundo a Agência Nacional de Energia Elétrica (ANEEL, 2008), o consumo de energia é um dos principais indicadores do desenvolvimento econômico e do nível de qualidade de vida de uma sociedade, refletindo tanto o ritmo de atividade dos setores produtivos quanto a capacidade da população de acessar bens e serviços tecnologicamente mais avançados. Essa relação direta entre consumo energético e desenvolvimento explica o crescimento expressivo da demanda energética observado nas últimas décadas. Entre as fontes renováveis, destaca-se o avanço das tecnologias emergentes. A geração eólica atingiu 107,7 TWh (+12,4%), enquanto a energia solar apresentou crescimento ainda mais expressivo, alcançando 70,7 TWh (+39,6%), evidenciando a transição energética em curso no país.

No consumo final de energia, houve aumento de 1,9%, com destaque para os setores industrial, residencial e de transportes, refletindo tanto o crescimento econômico quanto

a ampliação do acesso a bens e serviços energéticos, a **Figura 5** demostra isso no gráficos que mostra as variações do consumo setorial de energia elétrica de 2024 em relação ao ano anterior.

Figura 5 – consumo de energia elétrica por setor (2024)

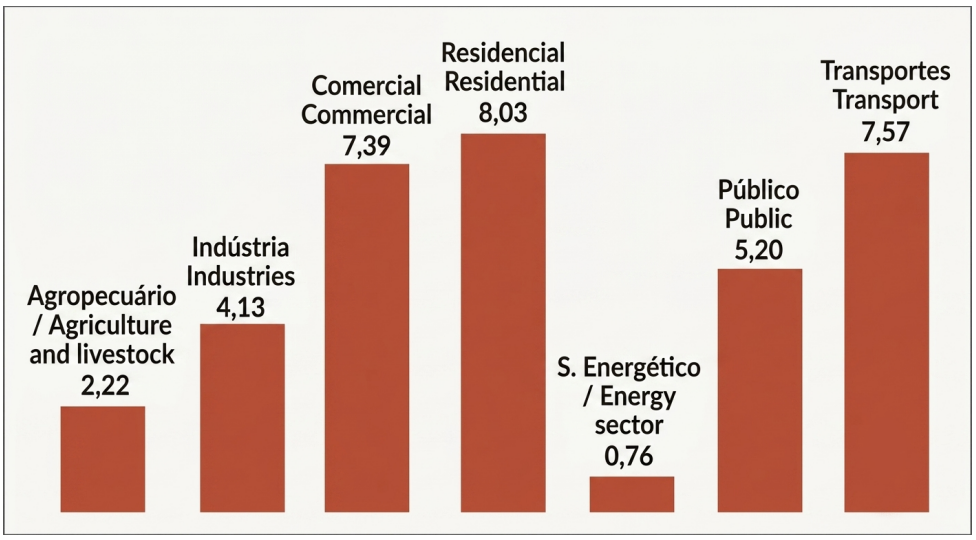


Fonte: Ministério de Minas e Energia – MME/ adaptada pelo autor (2026).

O consumo final foi de 650,4 TWh, representando uma expansão de 5,5% em comparação ao ano anterior, com destaque para os setores industrial e residencial, que participaram com 35,9% e 28,2% respectivamente.

Entretanto, o crescimento da demanda energética também traz desafios. Apesar dos avanços na diversificação da matriz, o uso de combustíveis fósseis ainda representa parcela significativa da matriz, especialmente no setor de transportes. Além disso, o setor energético brasileiro foi responsável por emissões de aproximadamente 431,3 milhões de toneladas de $CO_2$ equivalente em 2024, indicando a necessidade contínua de políticas voltadas à sustentabilidade e eficiência energética.

Nesse contexto, a eficiência energética refere-se à capacidade de obter o mesmo nível de serviço com menor consumo de energia, sendo reconhecida como uma das estratégias mais eficazes para reduzir custos operacionais e emissões de gases de efeito estufa (Wang et al., 2018; Worrell et al., 2009). Dessa forma, a eficiência energética consolida-se como um dos pilares fundamentais da transição energética global. O Brasil destaca-se internacionalmente por seus programas de eficiência energética, como o Programa Brasileiro de Etiquetagem (PBE) demostrado na Figura 6, que incentiva

o uso racional da energia por meio de políticas públicas e regulamentações técnicas (Souza et al., 2009).

Figura 6 – Etiqueta de eficiência energética

Fonte: Plenitude (2025).

### 2.1.2 EFICIÊNCIA ENERGÉTICA NAS INSTITUIÇÕES PÚBLICAS DE ENSINO

As instituições públicas de ensino desempenham papel fundamental na promoção do conhecimento e no desenvolvimento social, sendo também espaços estratégicos para a implementação de práticas sustentáveis. Nesse contexto, a eficiência energética (EE) destaca-se como uma ferramenta essencial para a gestão pública, alinhando-se ao princípio da eficiência administrativa previsto na Constituição Federal (BRASIL, 1988).

Nos últimos anos, o Brasil tem avançado na implementação de políticas e programas voltados à eficiência energética, especialmente no setor público. De acordo com a Empresa de Pesquisa Energética, as edificações são responsáveis por parcela significativa do consumo de energia elétrica no país, representando cerca de 47% do consumo total (EPE, 2024). Dentro desse contexto, edificações públicas incluindo instituições de ensino respondem por aproximadamente 7,6% do consumo elétrico nacional, com destaque para usos como climatização, iluminação e equipamentos (MME, 2023).

Nas instituições de ensino, o consumo energético está fortemente concentrado em sistemas de climatização, iluminação e equipamentos elétricos, sendo estes os principais alvos para ações de eficiência energética, uma vez que melhorias tecnológicas e operacionais podem gerar reduções significativas no consumo (LAMBERTS et al., 2004).

Figura 7 – Programas e legislações que tratam de sustentabilidade em IESF

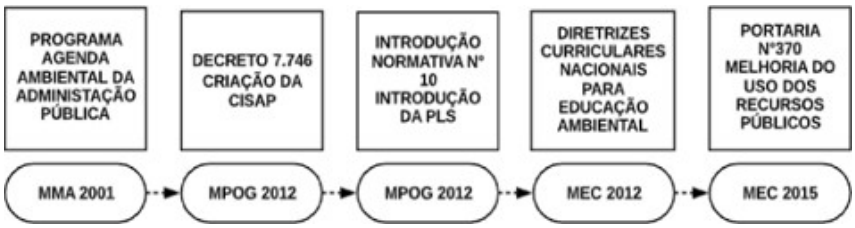


Fonte:Adaptado de LEITE (2018).

A partir da análise da **Figura 7**, observa-se que, desde os anos 2000, foram implementadas diversas iniciativas governamentais voltadas à sustentabilidade no setor público, incluindo instituições de ensino. Destacam-se programas como a Agenda Ambiental da Administração Pública (A3P), a criação da Comissão Interministerial de Sustentabilidade na Administração Pública (CISAP), além de diretrizes educacionais e normativas que incentivam práticas sustentáveis e o uso eficiente dos recursos públicos.

Estudos indicam que edificações públicas possuem elevado potencial de economia, podendo alcançar reduções expressivas por meio da modernização de sistemas, adoção de tecnologias eficientes e melhoria na gestão energética (EPE, 2024). Além disso, ações voltadas ao comportamento dos usuários, como o uso consciente da energia, também contribuem de forma relevante para a redução do consumo (LIMA, 2018).

A eficiência energética, nesse sentido, não se limita apenas à redução de custos operacionais, mas também está diretamente associada à sustentabilidade ambiental, contribuindo para a diminuição das emissões de gases de efeito estufa (WANG et al., 2018; WORRELL et al., 2009). Dessa forma, as instituições públicas de ensino devem atuar como agentes multiplicadores de práticas sustentáveis, promovendo não apenas a redução do consumo energético, mas também a conscientização da comunidade acadêmica (LEITE, 2018).

Assim, a adoção de medidas de eficiência energética em instituições públicas de ensino representa uma estratégia essencial para a gestão eficiente dos recursos públicos, a sustentabilidade ambiental e a formação de uma cultura energética mais responsável na sociedade.

## 2.2 INTELIGÊNCIA ARTIFICIAL

A Inteligência Artificial (IA) é um campo da Ciência da Computação dedicado ao desenvolvimento de sistemas capazes de simular a inteligência humana, realizando tarefas como reconhecimento de padrões, tomada de decisão e automação de processos como demostrado na figura 8 no teste de turing. Formalizada em 1956 na conferência de Dartmouth, organizada por John McCarthy, a IA evoluiu significativamente e hoje está presente em diversas áreas, contribuindo para a eficiência e inovação tecnológica.

Figura 8 – Teste de Turing: experimento que identifica se IA superou humanos.

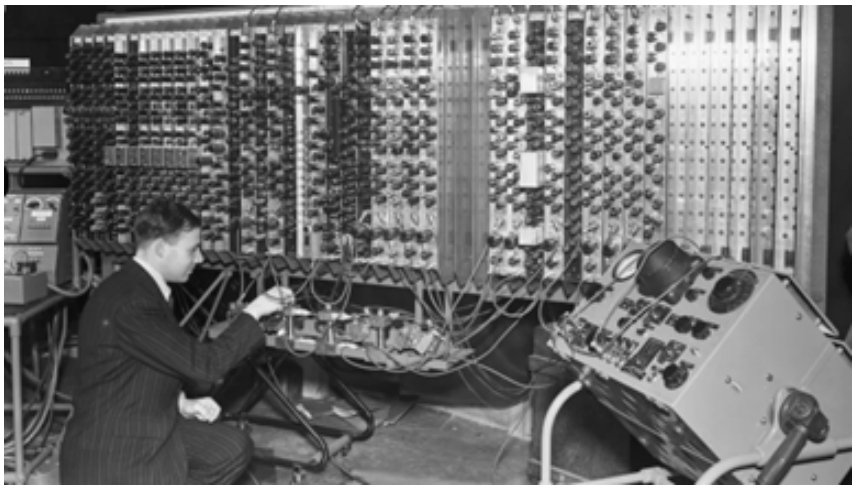

Fonte:Jimmy Sime (2025).

A Inteligência Artificial (IA) constitui um campo de estudo da Ciência da Computação e da Engenharia de Software dedicado ao desenvolvimento de métodos, algoritmos e sistemas capazes de executar tarefas que normalmente exigiriam capacidades humanas. Entre essas capacidades, destacam-se o planejamento orientado a objetivos, a tomada de decisão, a autonomia na execução de tarefas e a realização de processos cognitivos, como aprendizado e resolução de problemas (GARCIA, 2020; ZAWACKI-RICHTER, 2019). De acordo com Stuart Russell (2013), as definições de Inteligência Artificial podem ser organizadas em diferentes perspectivas, que consideram tanto a forma de raciocínio quanto o comportamento dos sistemas, agrupando-se em quatro categorias principais, conforme apresentado no Quadro 3.

Quadro 3 – Oito definições de IA

| Pensando como um humano | Pensando racionalmente |
|---|---|
| "[...] fazer os computadores pensarem (Haugeland, 1985 *apud* Russel, 2013).<br><br>"[Automatização de] atividades que associamos ao pensamento humano, atividades como a tomada de decisões, a resolução de problemas, o aprendizado [...]" (Bellman, 1978 *apud* Russel, 2013). | "O estudo das faculdades mentais pelo uso de modelos computacionais" (Charniak; McDermott, 1985 *apud* Russel, 2013).<br><br>"O estudo das computações que tornam possível perceber, raciocinar e agir" (Winston, 1992 *apud* Russel, 2013). |
| **Agindo como seres humanos** | **Agindo racionalmente** |
| "[...] criar máquinas que executam funções que exigem inteligência quando executadas por pessoas" (Kurzweil, 1990 *apud* Russel, 2013).<br><br>"O estudo de como os computadores podem fazer tarefas que hoje são melhor desempenhadas pelas pessoas" (Rich; Knight, 1991 *apud* Russel, 2013). | "Inteligência Computacional é o estudo do projeto de agentes inteligentes" (Poole *et al.*, 1998 *apud* Russel, 2013).<br><br>"AI [...] está relacionada a um desempenho inteligente de artefatos" (Nilsson, 1998 *apud* Russel, 2013). |

Fonte: Trindade; Oliveira (2023).

O termo Inteligência Artificial (IA) não se refere a uma única tecnologia, mas a um conjunto amplo de métodos, técnicas e abordagens voltadas ao desenvolvimento de sistemas capazes de realizar tarefas de forma inteligente. Esses sistemas utilizam dados para identificar padrões, aprender com experiências anteriores e tomar decisões de maneira autônoma ou assistida, buscando alcançar resultados adequados a determinados objetivos (RUSSELL, 2013; ZAWACKI-RICHTER, 2019).

## 2.3 MACHINE LEARNING (APRENDIZADO DE MÁQUINA)

No âmbito da eficiência energética, o emprego de técnicas de Aprendizado de Máquina (Machine Learning – ML) tem se mostrado fundamental para a modelagem de sistemas complexos. De acordo com Mitchell (1997), essa abordagem permite que sistemas computacionais melhorem seu desempenho em tarefas específicas por meio da experiência, prescindindo de uma programação baseada em regras rígidas e explícitas.

Diferentemente da Inteligência Artificial simbólica, que é fundamenta sua lógica em instruções detalhadas e sequenciais inseridas manualmente pelo programador, o ML baseia-se na capacidade de o algoritmo extrair padrões diretamente dos dados. Durante o processo de treinamento, o modelo processa um volume expressivo de exemplos para construir uma representação matemática robusta. Essa estrutura torna o sistema

apto a realizar inferências, como tarefas de classificação ou predição de variáveis, diante de dados inéditos.

Figura 9 – Como é o treinamento do algoritmo para identificar e classificar os spams

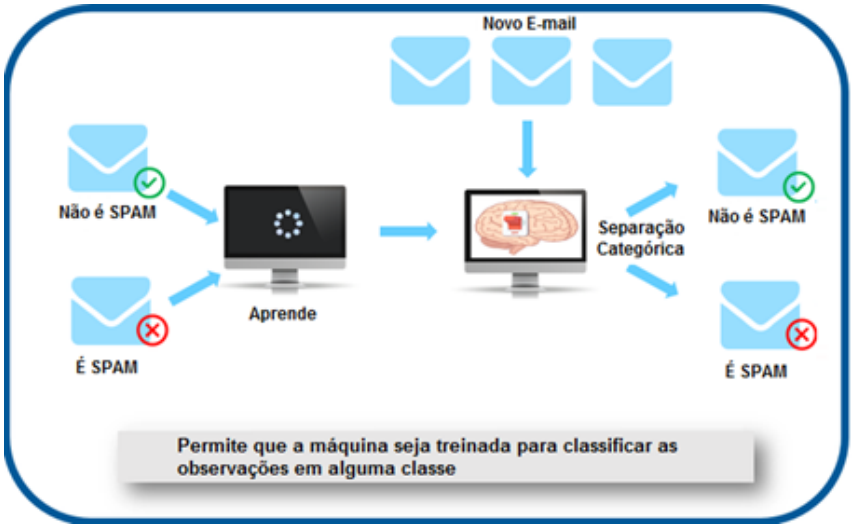


Fonte: PrograMaria (2026).

Um exemplo prático dessa aplicação, ilustrado na Figura 9, é o sistema de filtragem de correio eletrônico, que classifica mensagens como "spam"ou "não spam"a partir da análise de padrões em e-mails anteriores. Da mesma forma, algoritmos de regressão podem estimar valores de mercado imobiliário baseando-se em atributos específicos de um imóvel. Quando submetidos a um treinamento adequado, esses modelos alcançam elevados níveis de acurácia, tornando-se ferramentas poderosas para a tomada de decisão automatizada em ambientes dinâmicos.

Algoritmos como Random Forest, ARIMA e Redes Neurais Multicamadas (MLP), implementadas com frameworks como Keras e TensorFlow, têm sido amplamente utilizados para previsão de demandas, consumo energético e otimização de processos produtivos. Enquanto modelos estatísticos como o ARIMA são eficazes em séries temporais estacionárias, técnicas baseadas em ML apresentam maior flexibilidade e precisão em cenários de alta variabilidade (Viana et al., 2024; Brunato et al., 2025).

## 2.4 ALGORITMO RANDOM FOREST

O Random Forest é um algoritmo de Aprendizado de Máquina baseado em conjuntos (ensemble learning), proposto por Breiman (2001), que combina múltiplas árvores de decisão para aumentar a robustez e a precisão do modelo demostrados na figura 10.

Figura 10 – Estrutura de uma Random Forest

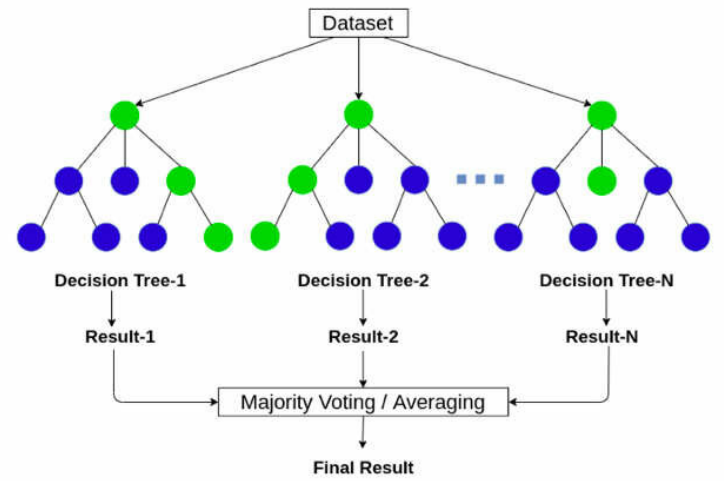


Fonte: RIBEIRO.D.M., (2021).

Cada árvore é construída a partir de subconjuntos aleatórios dos dados e das variáveis de entrada, reduzindo a correlação entre os modelos individuais e mitigando o problema de sobreajuste.

O Random Forest apresenta bom desempenho em problemas de regressão, sendo capaz de lidar com dados ruidosos e relações complexas, além de fornecer métricas de importância das variáveis, aspecto relevante para análises interpretáveis em sistemas energéticos.

## 2.5 MODELO ARIMA

O modelo ARIMA (AutoRegressive Integrated Moving Average) é uma técnica estatística tradicional utilizada para análise e previsão de séries temporais, especialmente quando há dependência entre observações ao longo do tempo (Box; Jenkins, 1976).

O modelo é definido por três parâmetros principais apresentado na figura 11: ordem autorregressiva (p), grau de diferenciação (d) e ordem da média móvel (q).

Figura 11 – Componentes de um modelo ARIMA(p, d, q).

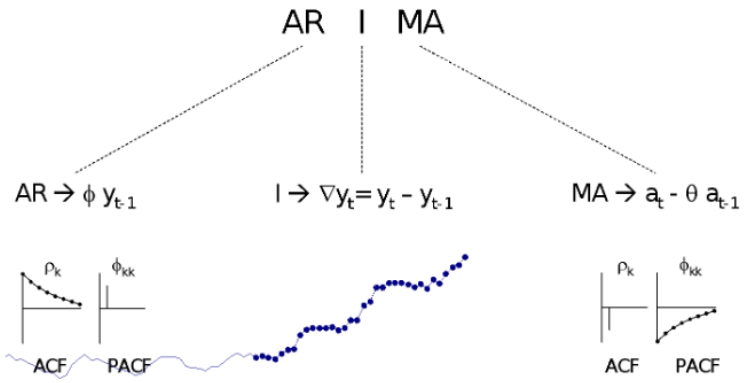


Fonte: DOMENECH.C (2025).

## 2.6 REDES NEURAIS

As Redes Neurais Artificiais (RNAs) são modelos computacionais inspirados no funcionamento do cérebro humano, compostos por unidades de processamento interconectadas, denominadas neurônios artificiais (Haykin, 2009) neurônios apresentados na figura 12.

Figura 12 – Neurônio Artificial(Perceptron).

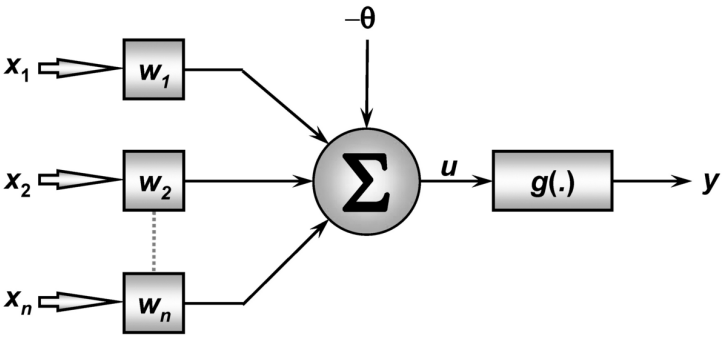


Fonte: da Silva et al (2016).

O Perceptron Multicamadas (Multilayer Perceptron – MLP) é uma das arquiteturas mais utilizadas, caracterizada por uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída.

Cada neurônio realiza operações matemáticas envolvendo pesos sinápticos, funções de ativação e termos de viés, aspectos amplamente discutidos na literatura técnica. As RNAs Figura 13 são particularmente eficazes na modelagem de relações não lineares

complexas, sendo amplamente empregadas em aplicações de previsão de consumo energético (Zhang et al., 1998).

Figura 13 – Redes Neurais Multicamadas.

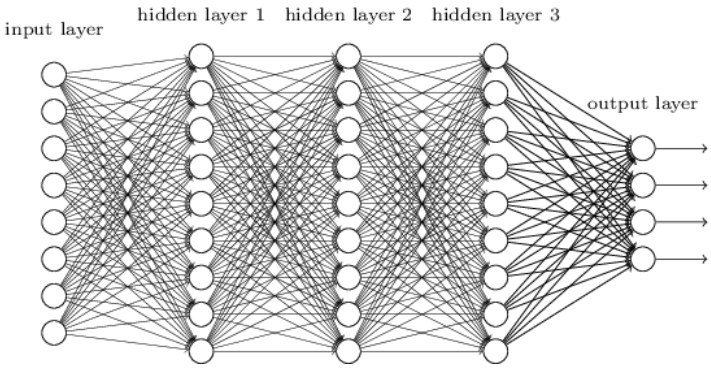


Fonte: Melo.c (2019).

Frameworks como Keras, integrados ao TensorFlow, facilitam a implementação e o treinamento de redes neurais, permitindo maior flexibilidade e escalabilidade no desenvolvimento de modelos preditivos como é apresentado na figura 14, a classificação da classe cachorro.

Figura 14 – Exemplo de classificação com rede neural. “Cachorro”

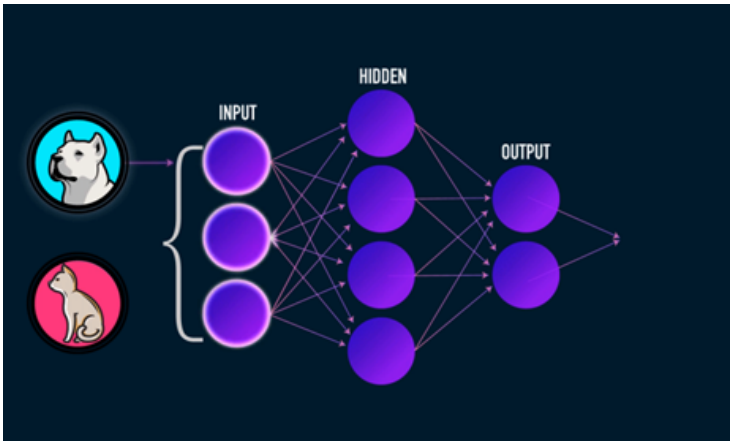


Fonte: Introdução a Deep Learning – Redes Neurais e TensorFlow (2026).

## 2.7 REDES NEURAIS RECORRENTES

As Redes Neurais Recorrentes (RNR ou RNN — Recurrent Neural Networks) são uma família de redes neurais profundas voltadas para o processamento de dados sequenciais, Abdalraouf Hassan and Ausif Mahmoud (2017). Da mesma forma como

um ser humano, ao ler um texto, a rede RNN busca entender cada palavra baseada no entendimento das palavras anteriores ou posteriores (contexto). Uma rede neural recorrente objetiva manter um dado de uma entrada anterior para que possa servir para o entendimento do dado atual. Este é um dos grandes motivos destas arquiteturas receberem tanta adesão no campo de previsões de séries temporais e em tarefas envolvendo Processamento de Linguagem Natural (NLP), Charu C Aggarwal et al (2018).

Figura 15 – Diagrama de uma Rede Neural Recorrente compacta e sua estrutura expandida no tempo.

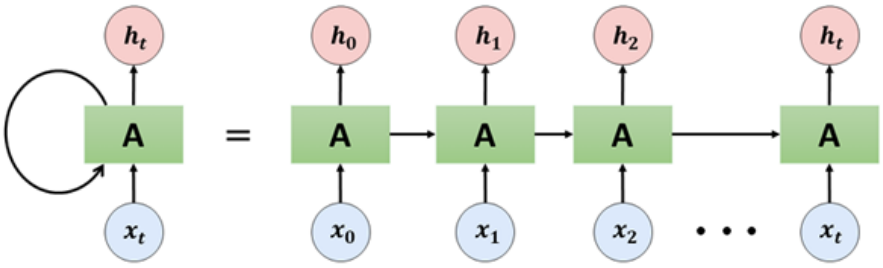


Fonte: Adaptado de Olah (2015).

As Redes Neurais Recorrentes (RNNs) distinguem-se por possuírem conexões cíclicas que permitem a persistência de informações, funcionando como uma memória interna. Conforme ilustrado na Figura 15, esse mecanismo de feedback possibilita que estados de entradas anteriores influenciem o processamento atual. Diferente das redes neurais convencionais, as RNNs utilizam a sequência temporal dos dados para o aprendizado, onde cada célula de memória transmite informações contextuais para a etapa subsequente.

Apesar de sua eficácia em sequências curtas, as RNNs apresentam limitações severas ao processar longas cadeias de dados devido ao fenômeno conhecido como Desvanecimento do Gradiente (Vanishing Gradient Problem). Esse problema ocorre durante o treinamento, especialmente quando funções de ativação como a sigmoide são empregadas; a multiplicação sucessiva de pequenas derivadas faz com que os gradientes diminuam exponencialmente conforme retrocedem nas camadas.

Como consequência, os pesos e biases das camadas iniciais não são atualizados

de forma eficiente, impedindo que a rede aprenda dependências de longo prazo e causando o "esquecimento"de informações remotas. Para superar essa deficiência e garantir a integridade do aprendizado em contextos complexos, surgiram arquiteturas variantes especializadas, como as redes Long Short-Term Memory (LSTM) e as Gated Recurrent Units (GRU), que utilizam mecanismos de portas (gates) para regular o fluxo e a retenção de memória.

### 2.7.1 REDE NEURAL RECORRENTE LSTM (LONG SHORT-TERM MEMORY)

As redes Long Short-Term Memory (LSTM) representam uma evolução das arquiteturas recorrentes, sendo projetadas especificamente para superar as limitações no processamento de informações em intervalos temporais extensos. A principal distinção da LSTM reside em sua capacidade de reter valores por períodos arbitrários, o que a torna ideal para a classificação e previsão em séries temporais onde a duração entre eventos relevantes é variável ou desconhecida. Diferente das RNNs tradicionais (frequentemente denominadas "vanilla") e dos Modelos Ocultos de Markov (MOM), que sofrem com a perda de contexto conforme a sequência de dados aumenta, a LSTM apresenta uma elevada insensibilidade ao comprimento do intervalo (gap) entre as informações. Enquanto modelos como o MOM dependem estritamente do estado oculto imediatamente anterior, perdendo a referência de longo prazo após múltiplos intervalos, a LSTM preserva o estado inicial por meio de sua estrutura de células de memória.

Figura 16 – Arquitetura interna de uma célula LSTM e seus mecanismos de portões (gates)

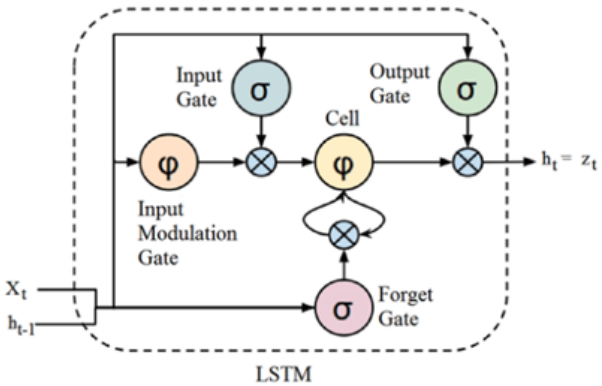


Fonte: Data Science Academy (2026).

Conforme ilustrado na Figura 16, a arquitetura interna de uma célula LSTM é composta por uma estrutura em cadeia que integra quatro redes neurais distintas. Essas redes operam como mecanismos de controle, denominados portões (gates), que regulam o fluxo de dados. Essa composição permite que a célula decida quais informações devem ser armazenadas, descartadas ou transmitidas para o próximo estado, garantindo a integridade do aprendizado mesmo em séries temporais complexas e de longa duração.

## 2.8 IOT

A Internet das Coisas permite a interconexão de dispositivos físicos, possibilitando a coleta e análise de dados em tempo real figura 17. Em ambientes industriais, a IoT, aliada a sistemas ciberfísicos e aprendizado de máquina, sustenta o conceito de fábricas inteligentes, caracterizadas por maior flexibilidade, adaptabilidade e descentralização da tomada de decisão (Atzori et al., 2010; Dos Santos Simão et al., 2019).

Figura 17 – Internet das Coisas: Conceitos e Aplicações

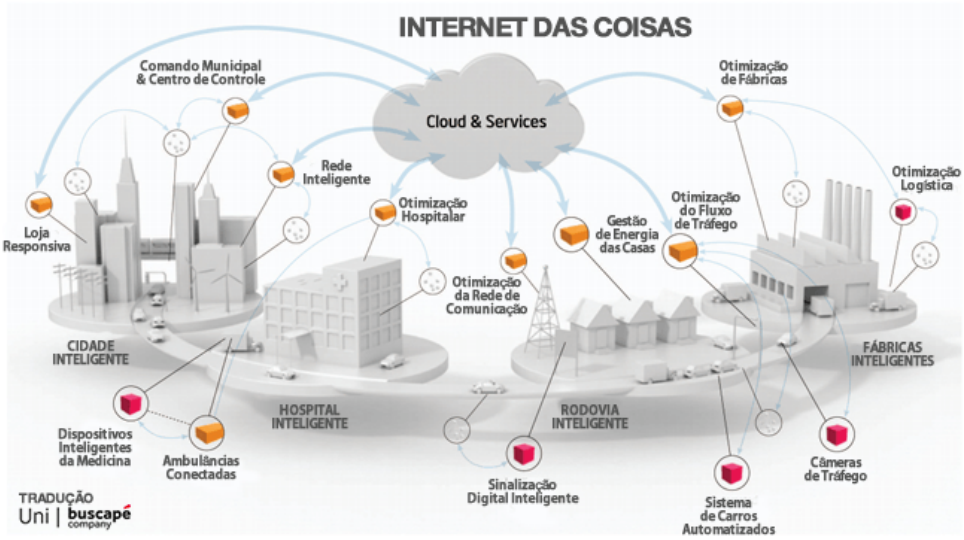


Fonte: ENERGIA INTELIGENTE (2016).

Estudos de caso em empresas como Bosch, Natura, Heineken e Renault demonstram que a integração entre monitoramento em tempo real, automação e análise inteligente de dados resulta em ganhos de produtividade, redução de custos e fortalecimento das práticas sustentáveis.

A literatura revisada evidencia que a convergência entre Indústria 4.0, eficiência ener-

gética, IA e IoT constitui um caminho estratégico para enfrentar os desafios produtivos, energéticos e ambientais das Instituições de ensino educacional. A aplicação integrada dessas tecnologias favorece uma gestão mais inteligente dos recursos, contribuindo para a sustentabilidade e a competitividade industrial.

## 2.9 CONCLUSÃO

Os estudos revisados evidenciam a crescente influência da IA, IoT e Robotic Process Automation na Indústria 4.0, abrangendo setores como automação industrial, previsão de demandas, monitoramento de infraestruturas e modelagem de recursos naturais. A integração dessas tecnologias potencializa a eficiência operacional, promovendo uma gestão mais inteligente e sustentável dos processos industriais, comerciais e educacionais, além disso autores como (SCHWAB, 2019), (BRYNJOLFSSON; MCAFEE, 2014) corroboram a importância dessas tecnologias na redefinição dos paradigmas produtivos e econômicos contemporâneos.

# 3 DESENVOLVIMENTO

O presente capítulo descreve o percurso metodológico seguido na pesquisa, detalhando os procedimentos técnicos adotados, os dispositivos e sensores utilizados para a coleta de dados, os processos de pré-processamento, as ferramentas computacionais aplicadas e os modelos de análise desenvolvidos. São apresentadas, ainda, as estratégias de implementação do sistema de monitoramento e do dashboard, bem como os critérios definidos para a validação dos resultados em ambiente laboratorial e no campus.

A pesquisa propõe o desenvolvimento de um sistema inteligente de baixo custo, baseado na IoT e na IA, destinado à otimização do consumo energético na instituição de ensino do Campus Ifes Vitória. O sistema integra a coleta de dados por sensores, o armazenamento em banco de dados relacional e análise de previsão com algoritmos de aprendizagem de máquina, permitindo monitorar, prever e otimizar o uso energético em tempo real.

## 3.1 ARQUITETURA DO SISTEMA E FLUXO DE DADOS

O sistema proposto para monitoramento e análise do consumo de energia elétrica é estruturado em quatro módulos principais: (1) coleta de dados, (2) transmissão de dados, (3) análise inteligente e (4) visualização dos resultados. Essa arquitetura permite a aquisição em tempo real das variáveis elétricas, seu armazenamento em nuvem, processamento por técnicas de inteligência artificial e apresentação dos resultados de forma interativa, conforme apresentado na figura 18.

Figura 18 – Diagrama de blocos do sistema inteligente de monitoramento energético.

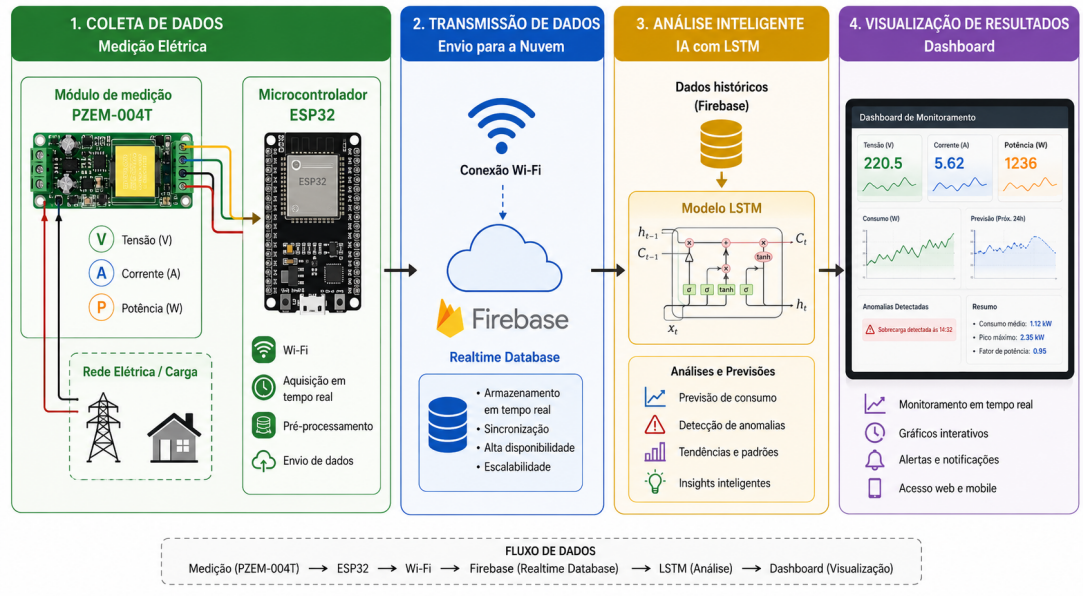


Fonte: Elaborado pelo autor (2026).

### 3.1.1 Módulo de Coleta de Dados

O módulo de coleta de dados é responsável pela aquisição das grandezas elétricas diretamente da rede ou da carga monitorada. Para isso, utiliza-se o sensor de medição elétrica PZEM-004T, capaz de mensurar, em tempo real, parâmetros como tensão (V), corrente (A) e potência (W). O PZEM-004T realiza a conversão dos sinais analógicos em dados digitais, os quais são transmitidos ao microcontrolador ESP32 por meio de comunicação serial (UART). O ESP32, por sua vez, executa a leitura periódica dessas informações, podendo realizar etapas de pré-processamento, como filtragem de ruídos e organização dos dados em estruturas adequadas para transmissão. Essa etapa é fundamental para garantir a confiabilidade das informações coletadas, uma vez que os dados serão utilizados posteriormente em processos de análise e previsão.

### 3.1.2 Módulo de Transmissão de Dados

Após a coleta, os dados são encaminhados para a nuvem por meio do módulo de transmissão. O microcontrolador ESP32 estabelece conexão com uma rede sem fio (Wi-Fi) atraves do roteador disponivel no projeto, possibilitando a comunicação com serviços remotos. Os dados são estruturados em formato compatível (como JSON) e enviados

para o Firebase Realtime Database, uma plataforma de banco de dados em tempo real que permite armazenamento, sincronização e acesso contínuo às informações. O envio pode ocorrer em intervalos regulares ou de forma contínua, dependendo da configuração do sistema. O uso do Firebase proporciona alta disponibilidade, escalabilidade e sincronização automática dos dados, permitindo que múltiplos clientes acessem as informações simultaneamente.

### 3.1.3 Módulo de Análise Inteligente

O módulo de análise inteligente é responsável pelo processamento dos dados coletados, utilizando técnicas de inteligência artificial baseadas em redes neurais recorrentes do tipo Long Short-Term Memory (LSTM). Inicialmente, os dados históricos armazenados no banco de dados são utilizados para o treinamento do modelo. A rede LSTM é especialmente adequada para análise de séries temporais, pois possui capacidade de capturar dependências de longo prazo e identificar padrões sequenciais no consumo de energia. Para a previsão do consumo energético, sera utilizado LSTM e o modelo ARIMA no ambiente google colab. Após o treinamento, o modelo é capaz de realizar previsões de consumo energético, bem como identificar comportamentos anômalos, como picos de carga ou variações fora do padrão esperado. Esses resultados contribuem para a tomada de decisão, possibilitando ações preventivas e otimização do uso de energia.

### 3.1.4 Módulo de Visualização de Resultados

O módulo de visualização tem como objetivo apresentar os dados coletados e processados de maneira clara e acessível ao usuário. Para isso, é utilizado um dashboard interativo conectado ao banco de dados em nuvem, desenvolvido em plataformas com interface web responsiva desenvolvida em HTML5, CSS3 e JavaScript (utilizando a biblioteca Chart.js para renderização de gráficos dinâmicos), que exibe indicadores de consumo, alertas automáticos e previsões de tendência. O dashboard permite o monitoramento em tempo real das variáveis elétricas, além da visualização de dados históricos e previsões geradas pelo modelo LSTM. As informações são exibidas por meio de gráficos, indicadores numéricos e alertas visuais, facilitando a interpretação

dos resultados. Adicionalmente, o sistema pode ser acessado por diferentes dispositivos, como computadores e smartphones, ampliando sua aplicabilidade e usabilidade em diversos contextos.

### 3.1.5 Fluxo Geral do Sistema

O fluxo de funcionamento do sistema pode ser descrito da seguinte forma: inicialmente, os dados elétricos são coletados pelo sensor PZEM-004T e enviados ao microcontrolador ESP32. Em seguida, essas informações são transmitidas via rede Wi-Fi para o Firebase, onde são armazenadas. Posteriormente, os dados são utilizados pelo modelo LSTM para análise e previsão. Por fim, os resultados são apresentados ao usuário por meio de um dashboard interativo. Essa integração entre hardware, computação em nuvem e inteligência artificial configura uma solução robusta para o monitoramento e análise do consumo energético em tempo real. Essa arquitetura apresentada na figura 19 garante uma integração completa entre hardware e software, possibilitando o monitoramento em tempo real e a aplicação de técnicas de aprendizado de máquina diretamente sobre os dados coletados.

Figura 19 – Fluxograma geral de funcionamento do sistema.

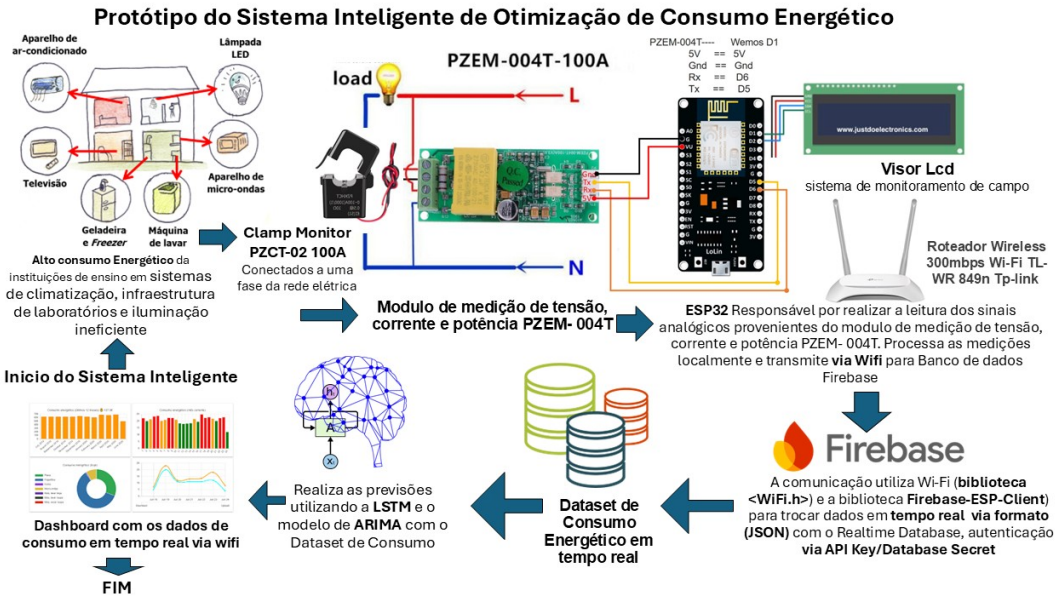


Fonte: Elaborado pelo autor (2026).

## 3.2 MATERIAIS E MÉTODOS

O presente projeto de pesquisa adota uma abordagem experimental e quantitativa, focada na implementação e validação de um sistema de aquisição de dados baseado em IoT e IA para a otimização do consumo energético do campus. A metodologia abrange a instrumentação de hardware, a arquitetura de comunicação e o processamento de dados abaixo na figura 20 uma breve descrição resumida dos principais componentes utilizados.

Figura 20 – Descrição resumida dos componentes e suas respectivas funções.

| Componente | Descrição / Função Principal |
|---|---|
| Modulo de medição de tensão, corrente e potência PZEM- 004T | Para fazer a leitura da rede elétrica e obter os valores de tensão, corrente e potência, foi escolhido o modulo PZEM-004T com o Clamp Monitor PZCT-02 100 A , por ele ser capaz de fazer todas as leituras de uma só vez, desta forma dando mais exatidão e confiabilidade ao sistema. |
| Microcontrolador ESP32 | Responsável por realizar a leitura dos sinais analógicos provenientes do modulo de medição de tensão, corrente e potência PZEM- 004T. Processa as medições localmente e transmite as informações via rede Wi-Fi para o servidor de dados Firebase na Nuvem. Possui conectividade integrada e baixo consumo de energia. |
| Visor LCD Alfanumérico HD44780 (Interface Local) | O sistema de monitoramento de campo incorpora um visor LCD alfanumérico com controlador HD44780 para fornecer feedback imediato sobre o status da medição e do sistema. |
| Firebase | O Firebase Realtime Database é um banco de dados hospedado na nuvem, e os dados são armazenados como JSON.<br>Diferentemente dos bancos de dados SQL, no Firebase não há tabelas, nem registros, e os dados são armazenados como objetos JSON, em uma arvore de objetos. |

Fonte: Elaborado pelo autor (2026).

Lista de materiais utilizados:

- Modulo de medição de tensão, corrente e potência PZEM- 004T.
- Bobina Clamp Monitor PZCT-02 100A.
- ESP32.
- Visor alfanumérico LCD HD44780.
- Módulo I2C.

- Roteador Wireless 300mbps Wi-Fi TL-WR 849n Tp-link.
- Disjuntor Termomagnético 3kA, 20A 1P.
- Caixa Hermética Vedada Ip68 250x200x130mm transparente.
- Plug e Tomada Macho/Fêmea 2P 10A250V.
- Protoboard 400 Pontos.
- Cabos Jumpers Macho/Femêa.
- Cabo de carregamento de dados tipo MicroUSB.
- Bateria Íon de Lítio 18650.
- resistores de 10k ohms.
- 1 resistor de 22 ohms.
- 1 capacitor eletrolítico de 10uF.

## 3.3 DESCRIÇÃO DO HARDWARE E PLATAFORMA DE COMUNICAÇÃO

A arquitetura do sistema de monitoramento é composta por componentes de hardware e software que atuam de forma integrada para a aquisição, o processamento e a comunicação dos dados de consumo elétrico do campus.

### 3.3.1 MODULO PZEM-004T

A aquisição de dados da rede elétrica é realizada pelo módulo multimétrico PZEM-004T, figura 21 selecionado por sua capacidade de integrar múltiplas leituras em um único barramento de comunicação. Diferente de arquiteturas que utilizam apenas sensores de corrente, este dispositivo realiza a medição direta da tensão e da corrente simultaneamente, o que assegura maior precisão e confiabilidade aos índices de consumo obtidos.

Figura 21 – Pzem-004T.

Fonte: Site Mercado Livre(2026).

A escolha por este componente foi motivada pelas instabilidades observadas na rede elétrica local durante os testes preliminares. Como a tensão apresenta variações constantes, a utilização de um valor nominal fixo para o cálculo de potência resultaria em erros acumulados significativos, comprometendo a precisão do sistema em comparação com as métricas oficiais da concessionária de energia. Com o PZEM-004T, o monitoramento reflete a realidade dinâmica da rede, garantindo dados fidedignos para a análise de eficiência energética.

Figura 22 – Bobina toroidal Clamp Monitor PZCT-02 100A.

Fonte: Site Mercado livre(2026).

O módulo é capaz de aferir tensão, corrente, potência ativa e energia acumulada. Para o monitoramento da corrente, o dispositivo utiliza uma bobina toroidal Clamp Monitor PZCT-02 100A (Figura 22) via indução, enquanto a tensão é medida através de conexão galvânica direta à rede. Com base nesses parâmetros, o hardware processa internamente a potência ativa e o consumo. Suas especificações técnicas compreendem uma faixa de operação para tensões entre 80 e 260 VAC e correntes que variam de 0 a 100 A, tornando-o apto para diversas aplicações no cenário industrial.

### 3.3.2 Microcontrolador ESP32 (Inteligência de Borda)

O núcleo de controle e processamento deste projeto é fundamentado no NodeMCU ESP32 (DevKit WROOM-32). Este dispositivo representa uma evolução tecnológica significativa em relação ao seu predecessor, o ESP8266, e às plataformas convencionais da família Arduino. Enquanto microcontroladores padrão utilizam CPUs de 8 bits com frequências reduzidas, o ESP32 é equipado com o microprocessador Xtensa® Dual-Core de 32 bits (LX6), operando com um clock que atinge até 240 MHz.

Figura 23 – NodeMCU ESP32 (DevKit WROOM-32).

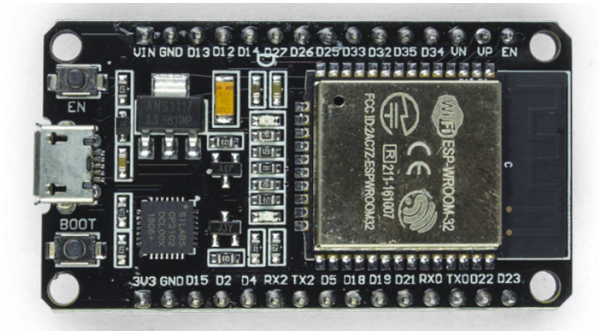


Fonte: Robocore (2026).

Projetado pela Espressif Systems, o ESP32 constitui uma solução de rede autossuficiente que integra, nativamente, conectividade Wi-Fi (802.11 b/g/n) e Bluetooth v4.2 (BR/EDR e BLE). Sua arquitetura de dois núcleos permite uma gestão otimizada das tarefas (multitasking): enquanto um núcleo pode ser dedicado exclusivamente à pilha de comunicação sem fio, o outro processa as rotinas de leitura de sensores e lógica de controle. O kit de desenvolvimento inclui uma interface USB-Serial para programação e um regulador de tensão interno, garantindo a estabilidade operacional em 3,3V. As principais especificações técnicas do NodeMCU ESP32 são detalhadas a seguir:

- Processamento: Xtensa® Dual-Core 32-bit LX6 com até 600 DMIPS;
- Memória: 520 KB de SRAM interna e 4 MB de Memória Flash;
- Conectividade: Wi-Fi 2.4 GHz e Bluetooth Dual-Mode;
- Tensão de Operação: 3,3V (suporta entrada externa de 4,5V a 9V via regulador integrado);

- Interfaces de I/O: 25 pinos GPIO com suporte a PWM (resolução de até 16 bits), ADC de 12 bits e DAC de 8 bits;
- Protocolos de Comunicação: Suporte nativo a UART, SPI e I2C;
- Segurança: Aceleração criptográfica por hardware (AES, SHA-2, RSA, ECC) e suporte a WPA/WPA2-Enterprise;
- Gestão de Energia: Múltiplos modos de baixo consumo, com corrente em Deep Sleep inferior a 10 µA;
- Ambiente de Operação: Resistência térmica entre -40 ºC e +85 ºC.

Figura 24 – Esquema de disposição das conexoes do NodeMCU ESP32 .

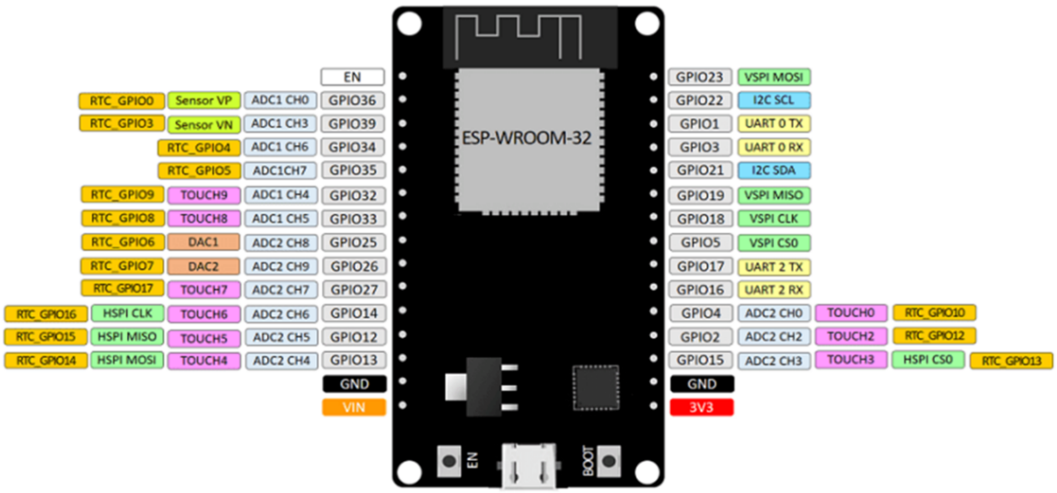


Fonte: Usinainfo(2026).

### 3.3.3 Visor LCD Alfanumérico HD44780 (Interface Local)

O sistema de monitoramento de campo incorpora um visor LCD alfanumérico com controlador HD44780 para fornecer feedback imediato sobre o status da medição e do sistema. Este controlador, desenvolvido pela Hitachi, é amplamente utilizado em displays compactos (o mais comum é o de 16 colunas por 2 linhas).

Figura 25 – Visor LCD 16x2 Alfanumérico HD44780.

Fonte: Mercado Livre (2026).

O visor lcd HD44780 apresentado na Figura 25 não exibe gráficos, sendo capaz apenas de representar caracteres ASCII (e alguns personalizados). O ASCII (American Standard Code for Information Interchange) é um padrão de codificação usado para representar letras, números e símbolos usando 8 bits. Para que um caractere (como "A", cujo código ASCII é "01000001"ou 65 em decimal) apareça no display, o microcontrolador envia esses valores pelos pinos de comunicação (Data 4 a Data 7) em duas etapas de 4 bits.

### 3.3.4 Infraestrutura de Rede: Roteador Wireless TL-WR849N

Para viabilizar a comunicação entre a camada de sensoriamento (ESP32) e o servidor de dados, utilizou-se o roteador TP-Link TL-WR849N. Este dispositivo desempenha a função de ponto de acesso (Access Point) central, sendo responsável por gerenciar o tráfego de pacotes e garantir a estabilidade da conexão local necessária para o envio contínuo das métricas energéticas.

Figura 26 – Roteador wireless TP-Link TL-WR849N

Fonte: Telekomm (2026).

A seleção deste hardware fundamenta-se na sua compatibilidade com o padrão IEEE 802.11n, que oferece taxas de transmissão de até 300 Mbps na frequência de 2,4 GHz. Tal capacidade é mais do que suficiente para o tráfego leve. Além disso, a presença de duas antenas externas de 5dBi amplia a sensibilidade de recepção e a cobertura do sinal, mitigando perdas de conexão em ambientes com interferências físicas ou eletromagnéticas comuns em cenários industriais ou laboratoriais.

### 3.3.5 Plataforma de Dados: Firebase Realtime Database

A persistência e a disponibilização dos dados coletados pelo sistema de monitoramento são gerenciadas através do Firebase Realtime Database Figura 27, uma plataforma de banco de dados NoSQL hospedada na nuvem e desenvolvida pela Google. Sua principal característica é a capacidade de sincronizar dados entre clientes em tempo real, o que permite que as métricas de consumo energético sejam atualizadas instantaneamente nas interfaces de monitoramento.

Figura 27 – Logotipo da plataforma Firebase (Google).

Fonte: Firebase.Google.com(2026).

Diferente dos bancos de dados relacionais tradicionais (SQL), que se baseiam em tabelas e registros estruturados, o Firebase armazena as informações como um único e vasto objeto JSON (JavaScript Object Notation) demostrado na Figura 28. Nesta arquitetura, os dados são organizados em uma estrutura de árvore hierárquica, onde cada nó representa uma chave que contém valores ou subconjuntos de dados. Esta abordagem oferece maior flexibilidade para o armazenamento de séries temporais de tensão, corrente e potência, permitindo a escalabilidade do sistema sem a necessidade de esquemas rígidos. O Firebase Realtime Database consolida-se como a infraestrutura de nuvem estratégica deste projeto, operando como o elo entre o hardware (ESP32) e a camada de visualização. Suas principais virtudes técnicas incluem:

- Sincronização Instantânea: Garantida pelo protocolo WebSockets, permitindo a replicação de dados em milissegundos para todos os clientes conectados.
- Resiliência de Dados: Suporte à persistência offline, que assegura a continuidade da operação do microcontrolador e a sincronização automática após falhas de conexão.
- Segurança Robusta: Integração com o Firebase Authentication e regras de acesso granulares, restringindo a manipulação de dados a dispositivos previamente autorizados.
- Agilidade Analítica: A arquitetura NoSQL em formato JSON simplifica o armazenamento e acelera a leitura das informações, otimizando o desempenho de dashboard voltados à gestão de eficiência energética.

Em suma, a plataforma funciona como um repositório centralizado, escalável e seguro, fundamental para o processamento das análises propostas neste trabalho, estrutura

disponível no repositório Github. https://github.com/edy71legal/Disserta-o-Eficiencia-Energertica-com-IoT-e-IA.git

Figura 28 – Estrutura de dados em árvore JSON no Realtime Database.


```
{
  "Monitoramento_Energia": {
    "Leituras": {
      "ID_Dispositivo_01": {
        "2026-05-06_16-40": {
          "tensao_V": 224.5,
          "corrente_A": 12.8,
          "potencia_W": 2873.6,
          "consumo_kWh": 154.22,
          "frequencia_Hz": 60.0
        },
        "2026-05-06_16-41": {
          "tensao_V": 223.8,
          "corrente_A": 13.1,
          "potencia_W": 2931.7,
          "consumo_kWh": 154.27,
          "frequencia_Hz": 60.0
        }
      }
    }
  }
}
```


Fonte: Firebase.Google.com (2026).

## 3.4 INSTRUMENTAÇÃO IOT E COLETA DE DADOS

### 3.4.1 Interface de Comunicação PZEM-004T para ESP32

A etapa de Instrumentação e prototipação IOT, iniciou-se com os microcontroladores ESP32 que foram programados na linguagem C++ com o todos os códigos disponíveis e demostrados no repositório do Github: https://github.com/edy71legal/Disserta-o-Eficiencia-Energertica-com-IoT-e-IA.git , utilizando a IDE Arduíno, Cada leitura contém valores de corrente, tensão e potência aparente, acompanhados de marca temporal. A comunicação é feita via protocolo Serial UART. A ligação segue este esquema de pinagem demostrado no Quadro 4.

Quadro 4 – Esquema de pinagem PZEM-004T para ESP32.

| Pino PZEM-004T | Pino ESP32 (Sugestão) | Descrição |
|---|---|---|
| **VCC** | 5V | Alimentação do circuito lógico do módulo. |
| **RX** | GPIO 17 (TX2) | Recebe os comandos enviados pelo ESP32. |
| **TX** | GPIO 16 (RX2) | Envia os dados medidos para o ESP32. |
| **GND** | GND | Referência comum (Terra). |

Fonte: Elaborado pelo autor (2026).

Esta montagem física garante que o ESP32 receba um fluxo contínuo de strings de dados, que serão então processadas e enviadas via Wi-Fi para o armazenamento no Firebase como podemos verificar na Figura 29.

Figura 29 – Comunicação entre PZEM-004T para ESP32.

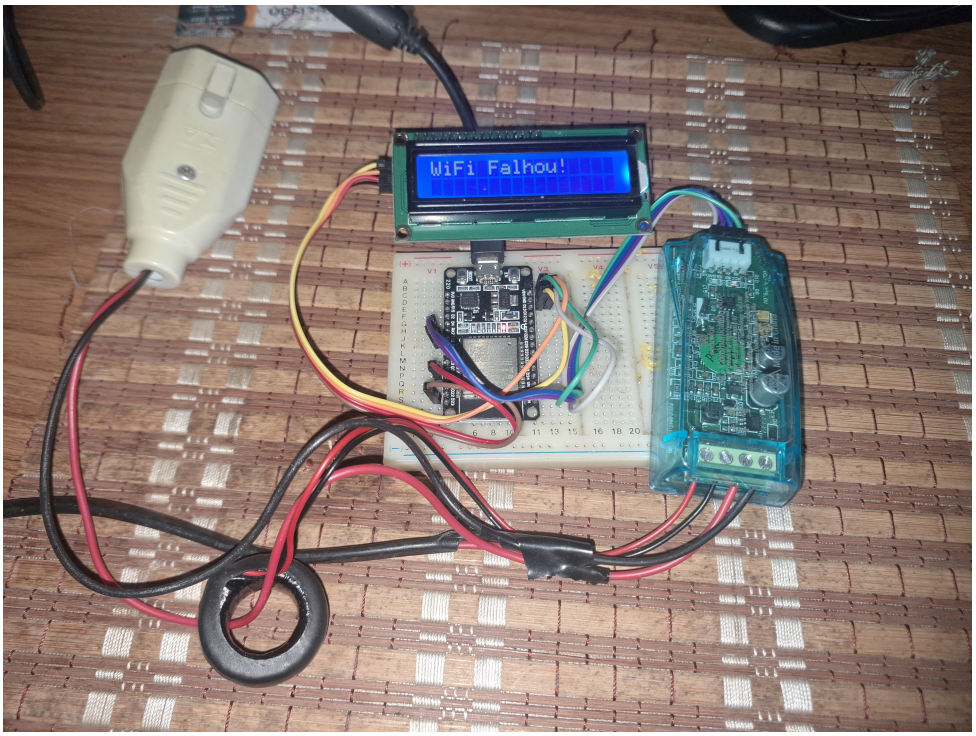


Fonte: Elaborado pelo autor (2026).

### 3.4.2 Montagem do Visor LCD com Módulo I2C no ESP32.

O sistema de feedback local do projeto utiliza o Visor LCD Alfanumérico HD44780 (16x2) acoplado a um Módulo Adaptador I2C (PCF8574). Na Figura 30 demostra o

processo de ligação das Conexões Físicas, realizado a simulação através da plataforma Wokwi disponível em https://wokwi.com/projects/419551632409584641 com código disponível no Github https://github.com/edy71legal/Disserta-o-Eficiencia-Energertica-com-IoT-e-IA.git, A fiação entre o Módulo I2C e o ESP32 figura 30 é direta e utiliza os pinos de comunicação I2C padrão do microcontrolador. Para validação local antes do envio ao Firebase, utiliza-se a conexão de um Display LCD 16x2 via I2C nos pinos SDA (GPIO 21) e SCL (GPIO 22) para exibir instantaneamente a Tensão, Consumo, Corrente e Potência.

Figura 30 – Diagrama elétrico de Conexão Módulo I2C e o ESP32.

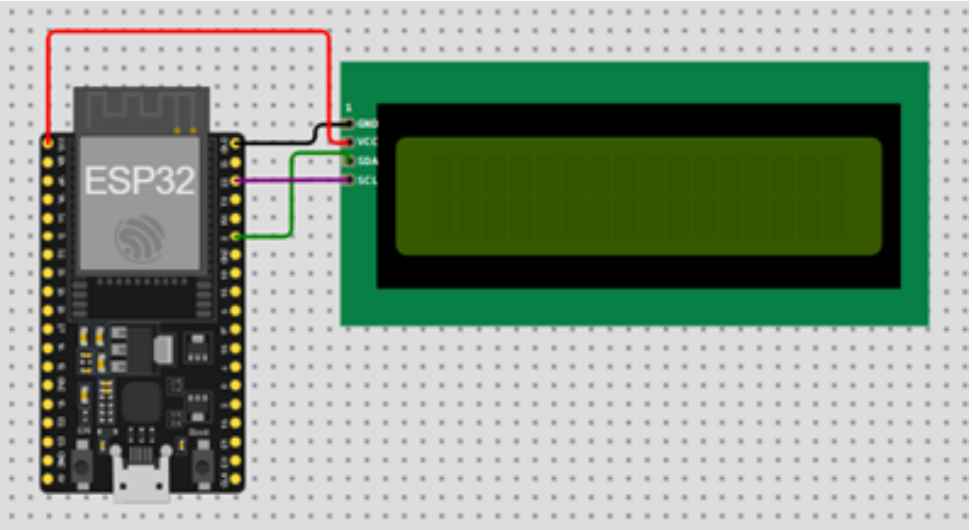


Fonte: Elaborado pelo autor (2026).

### 3.4.3 Configuração de Software e Instrumentação

A instrumentação do visor LCD, essencial para fornecer o feedback operacional no ambiente de IoT. O processo de programação e configuração começa com a inclusão das bibliotecas necessárias como demostrado na figura 31; É obrigatória a inclusão da biblioteca Wire.h, que gerencia o protocolo de comunicação I2C, e de uma biblioteca específica para o controle do LCD via I2C, como a LiquidCrystal-I2C. https://github.com/edy71legal/Disserta-o-Eficiencia-Energertica-com-IoT-e-IA.git

Figura 31 – trecho do código do visor na parte das bibliotecas.

Fonte: Elaborado pelo autor (2026).

Desta forma, o LCD cumpre um papel duplo: ele atua como uma ferramenta de debug durante o desenvolvimento e serve como interface de feedback operacional local para o ambiente industrial, garantindo que a informação essencial esteja visível mesmo em caso de falha temporária na rede (IoT).

Figura 32 – Foto do visor com interface de feedback.

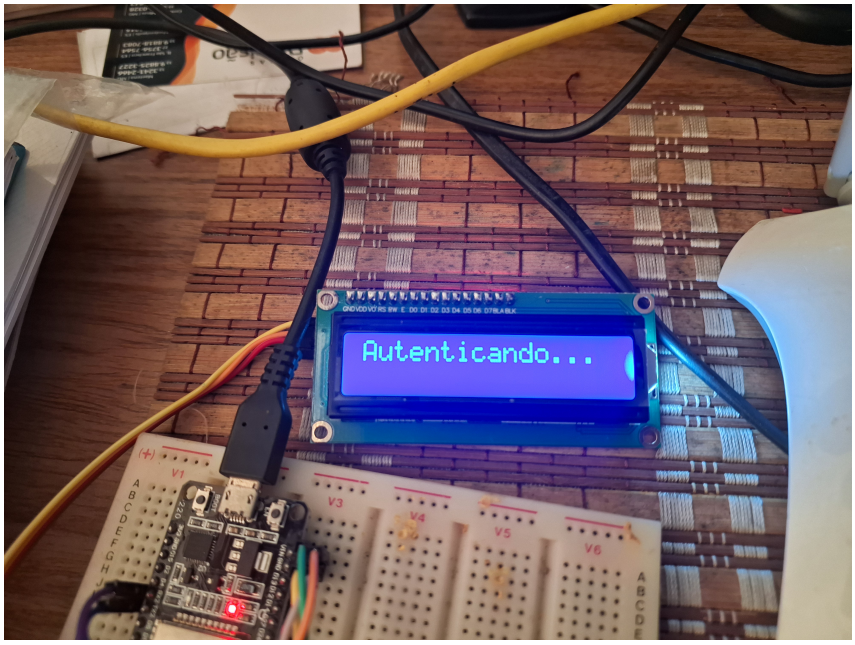


Fonte: Elaborado pelo autor (2026).

### 3.4.4 Condicionamento e Montagem dos componentes do protótipo

A arquitetura de monitoramento proposta fundamenta-se na convergência entre a rede de potência em corrente alternada e a camada de instrumentação lógica digital. No domínio da potência, a instalação elétrica centra-se na Bobina toroidal Clamp Monitor PZCT-02 100A juntamente com o sensor PZEM-004T, integrado diretamente ao Quadro de Distribuição de Circuitos (QDC) demostrado na Figura 33. Sua montagem é realizada em trilho DIN de 35 mm, posicionado em série com a carga monitorada. Diferente de sistemas baseados exclusivamente em sensores de corrente não invasivos, este dispositivo exige que os condutores de fase e neutro, provenientes da proteção geral, sejam conectados aos seus terminais de entrada.

Figura 33 – Diagrama de instalação elétrica e IoT.

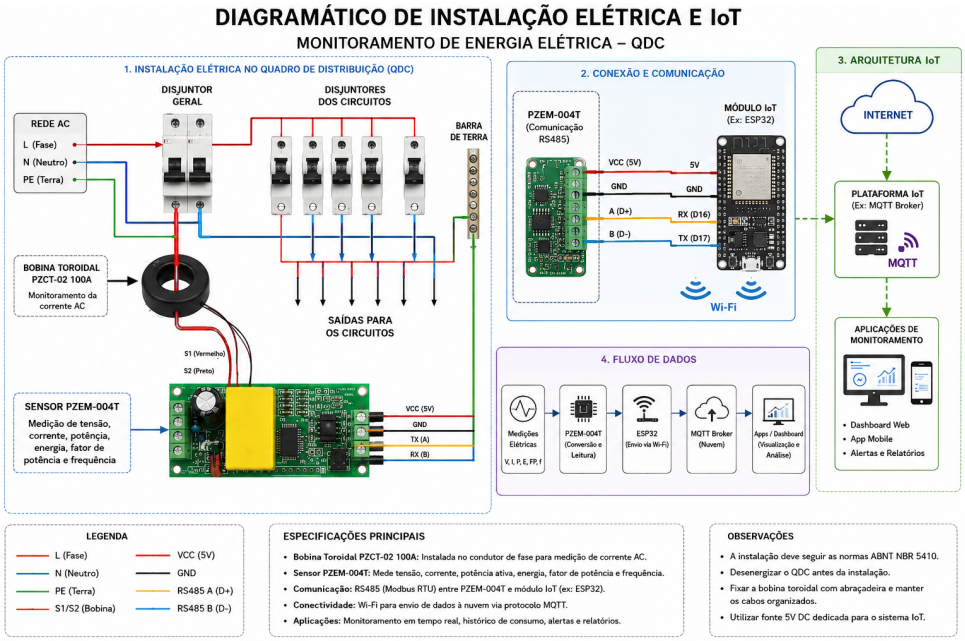


Fonte: Elaborado pelo autor (2026).

Paralelamente à infraestrutura elétrica, a malha de instrumentação lógica opera de forma sem fio, utilizando o protocolo TCP/IP sobre redes Wi-Fi no padrão IEEE 802.11b/g/n. O fluxo de dados é mediado pelo microcontrolador ESP32, que assume a função de gateway IoT, o ESP32 estabelece uma conexão cliente-servidor na rede wifi local, autenticando-se por meio de uma chave criptográfica AES-128 (Local Key) no roteador TP-Link TL-WR849N. Uma vez estabelecido o canal de comunicação, o gateway realiza requisições periódicas dos estados dos Data Points (DPs) internos

do medidor PZEM-004T, capturando valores brutos de tensão, corrente e potência conforme demostrado na Figura 34.

Figura 34 – Foto do Protótipo e instrumentação pronta.

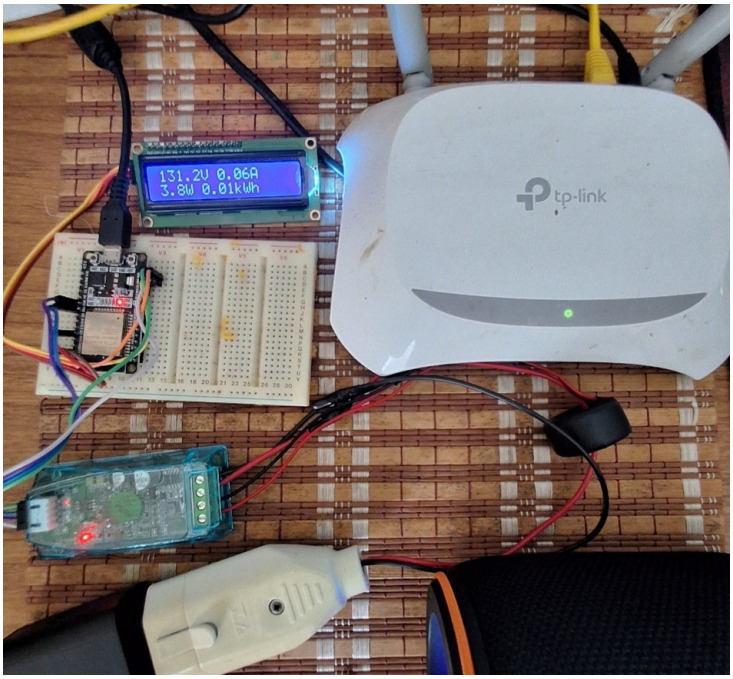


Fonte: Elaborado pelo autor (2026).

O processamento subsequente no ESP32 envolve o escalonamento dessas grandezas para unidades do Sistema Internacional e o encapsulamento das informações em objetos JSON (JavaScript Object Notation). Esta estruturação sera alojada em uma caixa hermética vedada Ip68 250x200x130mm transparente como apresentada na Figura 35 que é fundamental para garantir a interoperabilidade semântica do sistema. Por fim, os dados são publicados via um servidor firebase centralizado na nuvem em banco de dados em tempo real. Esta disposição arquitetural assegura que, embora o sistema realize o controle de cargas de alta potência, as unidades de processamento e inteligência operem em baixa tensão e de forma logicamente isolada, conferindo robustez e segurança à instrumentação proposta.

Figura 35 – caixa hermética vedada Ip68 250x200x130mm.

Fonte: Elaborado pelo autor (2026).

### 3.4.5 Implementação e Estrutura do Banco de Dados Firebase

A infraestrutura de dados desta pesquisa utiliza o Firebase Realtime Database, um banco de dados NoSQL hospedado na nuvem que permite o armazenamento e a sincronização de dados em tempo real entre todos os clientes conectados, Figura 36.

Figura 36 – Projeto Firebase consumo-conciente.

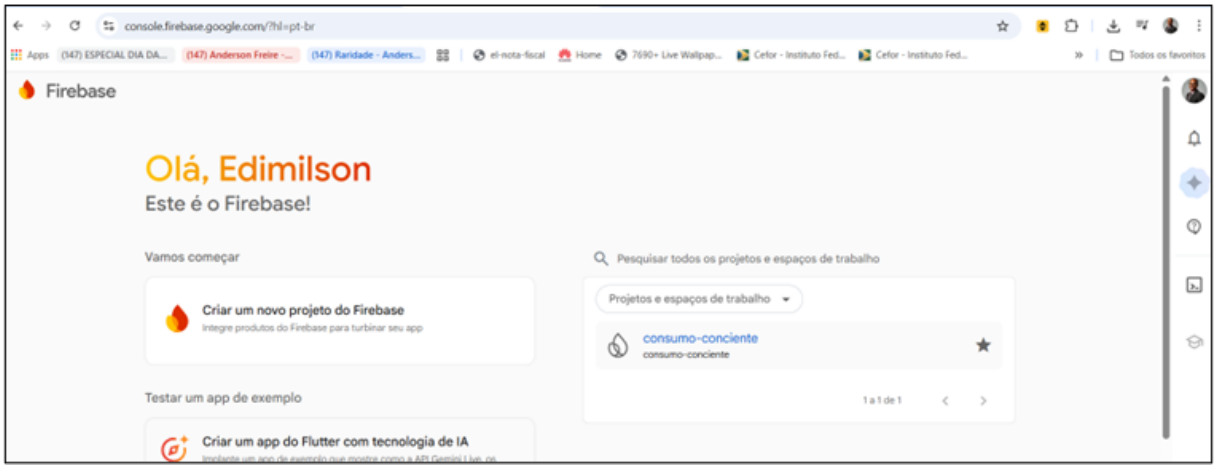


Fonte: Elaborado pelo autor (2026).

Esta escolha estratégica justifica-se pela sua arquitetura baseada em eventos, que elimina a necessidade de requisições HTTP constantes, otimizando o tráfego de rede e a autonomia energética dos dispositivos IoT. O banco de dados foi estruturado de forma otimizada para o armazenamento de séries temporais, contendo campos essenciais na

tabela de medições estruturados em JSON demostrado na Figura 37 e com dataset do firebase disponível no Github, https://github.com/edy71legal/Disserta-o-Eficiencia-Energertica-com-IoT-e-IA.git.

Figura 37 – Estrutura JSON da tabala leituras


```
{
  "leituras": {
    "2026-05-07": {
      "consumo_referencia_dia": 145.20,
      "11-00-00": {
        "voltagem": 127.5,
        "corrente": 1.2,
        "potencia": 153.0,
        "consumo_total_pzem": 145.35,
        "consumo_diario": 0.15
      },
      "11-15-00": {
        "voltagem": 126.9,
        "corrente": 1.15,
        "potencia": 145.0,
        "consumo_total_pzem": 145.85,
        "consumo_diario": 0.65
      }
    }
  }
}
```


Fonte: Elaborado pelo autor (2026).

A modelagem dos dados foi estruturada de forma hierárquica seguindo o padrão de objetos JSON, organizada em nós cronológicos para facilitar a extração de séries temporais necessárias aos modelos de previsão LSTM e ARIMA. A hierarquia foi definida da seguinte forma:

- Nó Raiz (consumo-energético): Ponto de entrada central para todos os dispositivos.
- Identificador do Dispositivo (campus-vitoria- lab): Diferencia os dados coletados por diferentes protótipos instalados.
- Carimbo de Tempo (Timestamp): Organizado pelo formato (-ANO-MES-DIA-HORA-MIN-SEG) para garantir consultas rápidas e ordenação automática.
- Atributos de Medição: Cada registro contém os seguintes campos técnicos capturados pelo sensor PZEM-004T:
- Tensão (V): Medida em Volts;

- Corrente (A): Medida em Ampéres;
- Potência Ativa (W): Medida em Watts;
- Energia Acumulada (kWh): Total de consumo registrado.

### 3.4.6 Implementação Técnica

A integração entre o microcontrolador ESP32 e a nuvem foi realizada através da biblioteca Firebase ESP Client. As etapas de implementação compreenderam:

- **Sincronização Temporal:** Utilização da biblioteca NTPClient para obter o horário preciso via servidores Network Time Protocol, garantindo que cada leitura de energia seja indexada com a hora exata da ocorrência, dado crucial para o treinamento da rede neural LSTM.
- **Protocolo de Comunicação:** O ESP32 estabelece uma conexão persistente via WebSockets, permitindo que as variações de carga detectadas pelo sensor sejam "empurradas"(push) para o banco de dados instantaneamente.
- **Resiliência e Segurança:** Configuração de regras de segurança para restringir a escrita de dados apenas ao protótipo autenticado via Token de Autenticação (Security Rules) conforme mostrado na Figura 38. Foi implementado um mecanismo de buffer local simples para lidar com instabilidades momentâneas na rede Wi-Fi do campus.

Figura 38 – Token de autenticação database secret firebase.

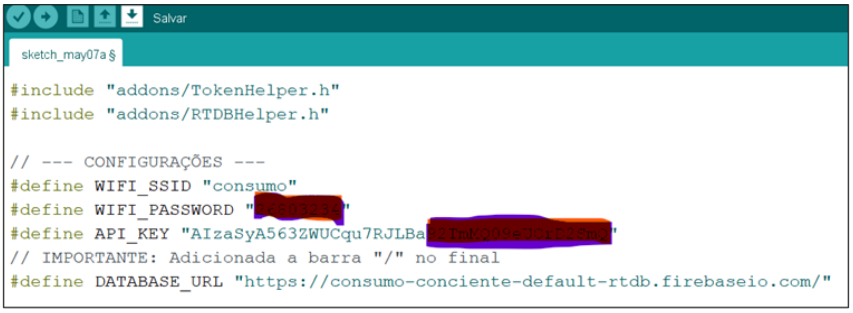


Fonte: Elaborado pelo autor (2026).

A implementação no Firebase consolida o fluxo de dados entre o sensor PZEM-004T e a nuvem, garantindo integridade e baixa latência via indexação temporal (NTP). Essa estrutura hierárquica em JSON viabiliza o monitoramento em tempo real e estabelece o dataset cronológico necessário para o treinamento dos modelos preditivos LSTM e ARIMA.

## 3.5 ETAPA DE COLETA DE DADOS

### 3.5.1 Ambiente de Testes e Validação

A geração de dados foi dividida em duas fases principais:

1. Fase Residencial (Bancada): Testes iniciais realizados para validar a precisão dos sensores e a resiliência da conexão Wi-Fi. Nesta fase, o mecanismo de buffer local do ESP32 foi essencial para garantir a integridade do dataset mesmo em casos de instabilidade de rede.
2. Fase Laboratorial (IFES - Campus Vitória): Transição para um ambiente controlado com fontes reguláveis e instrumentos de precisão (osciloscópios e analisadores), simulando cargas de uma linha de produção real.

### 3.5.2 Dataset de Consumo Residencial de bancada

O resultado desta etapa é a entrega de um Dataset de Consumo Energético em Tempo Real, composto por quatro variáveis fundamentais:Tensão (V) e Corrente (A) (Parâmetros elétricos brutos). Potência Ativa (W) (Indicador de carga instantânea). Energia Acumulada (kWh) (Consumo histórico total). A etapa de coleta de dados foi conduzida com a instalação de sensores IoT em ambiente residencial e posteriormente em ambiente Laboratorial. Os sensores de corrente PZEM-004T foram empregados para mensurar o consumo elétrico dos laboratórios do campus, para monitorar o uso de consumo de energia em processos de uso a cada 15 minuto, demostrado na Figura 39 de teste.

Figura 39 – processos de leitura a cada 15 minuto de teste de bancada.

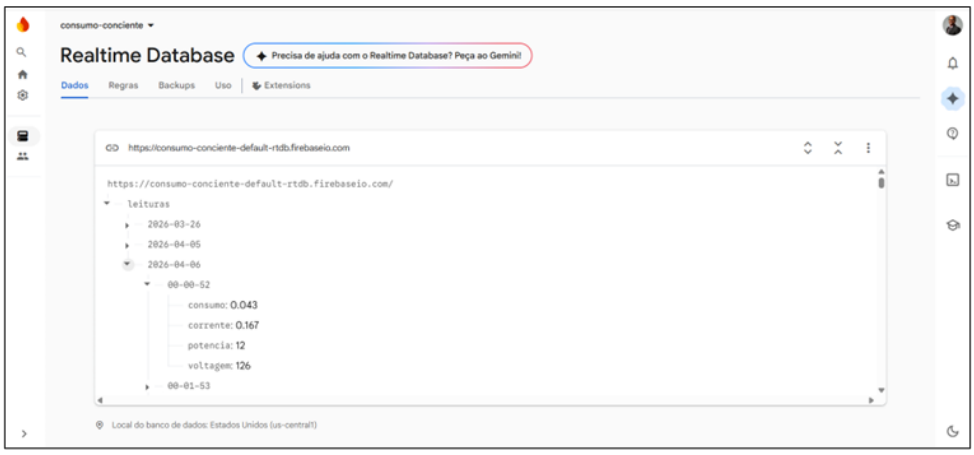


Fonte: Elaborado pelo autor (2026).

Os testes iniciais foram realizados com os sensores de monitoramento instalados em bancada na minha própria residencia conforme demostrado na Figura 40, apos esta etapa os testes se dará no laboratório do IFES – Campus Vitoria, simulando as condições de operação da linha de produção dos Laboratórios do Campus Vitoria.

Figura 40 – Testes de coletas iniciais de bancada residencial.

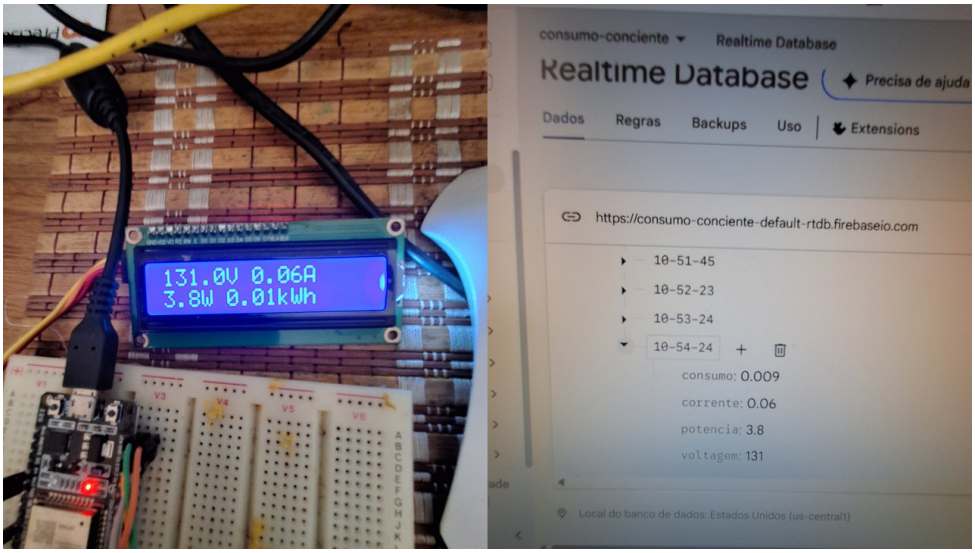


Fonte: Elaborado pelo autor (2026).

Esses espaços oferecem infraestrutura adequada para medições elétricas, integração de sensores IoT e experimentação com modelos de IA, contando com bancadas equipadas com fontes de energia reguláveis, instrumentos de medição (multímetros, osciloscópios e analisadores de energia), além de rede Wi-Fi institucional e estações

de monitoramento de dados.

### 3.5.3 Banco de dados do consumo gerado na bancada de testes

1. Estrutura Hierárquica e Formato

   Os dados foram organizados seguindo o padrão de objetos JSON, estruturados em nós cronológicos que garantem a ordenação automática e a integridade das informações:

   - Nó Raiz: Denominado **consumo-energético**, concentrando todos os registros.
   - Organização Temporal: Os dados estão indexados pelo formato (ANO-MÊS-DIA-HORA-MIN-SEG). Esta estrutura permite a extração imediata de fatias temporais específicas para análise.

2. Conteúdo das Amostras (Atributos)

   - Tensão (V): Potencial elétrico medido em Volts.
   - Corrente (A): Intensidade da corrente medida em Ampéres.
   - Potência Ativa (W): Consumo instantâneo em Watts.
   - Energia Acumulada (kWh): O somatório do consumo ao longo do tempo de teste.

O banco de dados do consumo gerado na bancada de testes esta disponível no repositório Github https://github.com/edy71legal/Disserta-o-Eficiencia-Energertica-com-IoT-e-IA/blob/main/consumo-conciente-default-rtdb-export.json

### 3.5.4 Granularidade e Volume

Durante os testes de bancada, a geração de dados foi otimizada para equilibrar a precisão e o volume de armazenamento.

- Intervalo de amostragem: Embora o sistema suporte leituras a cada minuto, o dataset final foi estruturado para suportar intervalos de 5 a 15 minutos.

- Otimização: A amostragem a cada 15 minutos, por exemplo, resulta em 2.880 leituras mensais, seguindo o padrão de concessionárias de energia.

Este volume de dados é ideal para garantir a convergência dos seus modelos de predição, abaixo na tabela 1 estão os detalhes quantitativos do dataset gerado.

Tabela 1 – Resumo quantitativo das amostras do dataset.

| **Parâmetro** | **2.880 leituras** |
|---|---|
| **Amostras por Dia** | 96 (baseado no intervalo de 15 min) |
| **Frequência de Coleta** | 1 leitura a cada 15 minutos |
| **Período Simulado** | 01/05/2026 a 30/05/2026 |
| **Formato de Saída** | JSON (Compatível com LSTM/ARIMA) |

Fonte: Elaborado pelo autor (2026).

### 3.5.5 Estrutura do Dataset de 30 Dias

O arquivo contém as seguintes colunas técnicas, conforme sua implementação no ESP32 e Firebase:

- **timestamp-unix:** Identificador temporal absoluto.
- **data-hora:** Carimbo de tempo legível (NTP).
- **tensao-v:** Oscilações de tensão simuladas em torno de 127V.
- **corrente-a:** Variações de carga (maior em horário comercial, menor em stand-by).
- **potencia-w:** Potência ativa calculada.
- **energia-acumulada-kwh:** O somatório crescente do consumo ao longo dos 30 dias.

Este volume de 2.880 amostras é exatamente o que você descreveu como o padrão recomendado para reduzir o tráfego de rede sem perder a qualidade do monitoramento residencial e laboratorial. O arquivo gerado do dataset de teste residencial utilizado nesta

dissertação está disponível no repositório Github https://github.com/edy71legal/Disserta-o-Eficiencia-Energertica-com-IoT-e-IA/blob/main/consumo-conciente-default-rtdb-export.json, abaixo na Figura 41 um recorte do dataset gerado no firebase.

Figura 41 – Recorte do dataset de bancada gerado no Firebase.

dataset_30_dias_bancada.csv

| | A | B | C | D | E | F |
|---|---|---|---|---|---|---|
| 1 | timestamp_unix | data_hora | tensao_v | corrente_a | potencia_w | energia_acumulada |
| 2 | 1777593600 | 2026-05-01 0:00:00 | 126.5 | 0.48 | 55.86 | 0.014 |
| 3 | 1777594500 | 2026-05-01 0:15:00 | 127.93 | 0.339 | 39.9 | 0.024 |
| 4 | 1777595400 | 2026-05-01 0:30:00 | 125.62 | 0.162 | 18.72 | 0.0287 |
| 5 | 1777596300 | 2026-05-01 0:45:00 | 125.23 | 0.446 | 51.38 | 0.0415 |
| 6 | 1777597200 | 2026-05-01 1:00:00 | 127.4 | 0.383 | 44.89 | 0.0527 |
| 7 | 1777598100 | 2026-05-01 1:15:00 | 125.08 | 0.488 | 56.16 | 0.0667 |
| 8 | 1777599000 | 2026-05-01 1:30:00 | 128.33 | 0.185 | 21.84 | 0.0722 |
| 9 | 1777599900 | 2026-05-01 1:45:00 | 125.73 | 0.173 | 20.01 | 0.0772 |
| 10 | 1777600800 | 2026-05-01 2:00:00 | 126.22 | 0.31 | 36 | 0.0862 |
| 11 | 1777601700 | 2026-05-01 2:15:00 | 126.73 | 0.216 | 25.18 | 0.0925 |

Fonte: Elaborado pelo autor (2026).

Este dataset final atua como a base de dados histórica necessária para o treinamento dos modelos preditivos LSTM (Long Short-Term Memory) e ARIMA, fornecendo o contexto cronológico exato para a análise de eficiência energética.

## 3.6 ARQUITETURA GERAL DO ECOSSISTEMA DE MONITORAMENTO

O ecossistema proposto foi concebido sob a premissa de modularidade e baixo acoplamento, sendo estruturado em quatro camadas fundamentais: captura física, persistência em nuvem, processamento analítico/inteligente e interface de operação. O fluxo de dados inicia-se na medição de grandezas elétricas industriais por meio de hardware dedicado e se estende até a disponibilização de telemetrias analíticas e alertas preditivos em um painel computacional, ilustrado na Figura 42.

Figura 42 – Arquitetura de fluxo e pipeline de dados do sistema integrado.

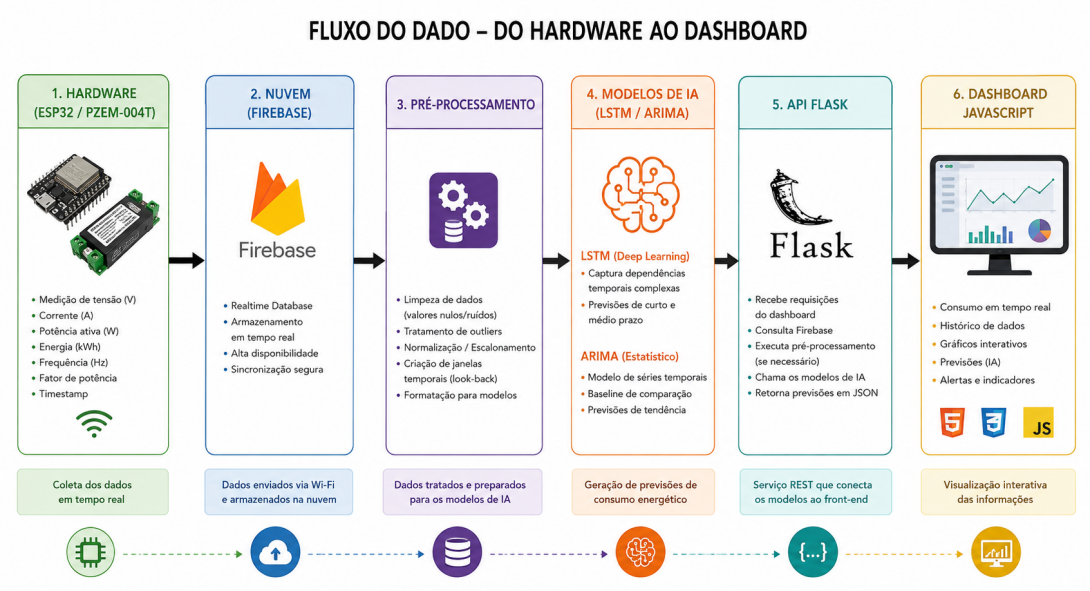


Fonte: Elaborado pelo autor (2026).

A topologia metodológica organiza-se conforme os seguintes domínios:

1. **Hardware (ESP32/PZEM-004T):** Aquisição contínua das grandezas elétricas (tensão, corrente, potência, energia, frequência e fator de potência) por meio do módulo de monitoramento, com transmissão dos dados via rede Wi-Fi.

2. **Nuvem (Firebase):** Armazenamento e sincronização em tempo real das medições, garantindo disponibilidade, persistência e acesso aos dados pelos módulos computacionais.

3. **Pré-processamento:** Tratamento algébrico dos dados, incluindo limpeza, remoção de inconsistências, normalização estatística e organização das séries temporais para alimentação dos modelos preditivos.

4. **Modelos de IA (LSTM/ARIMA):** Processamento das séries temporais por modelos de Inteligência Artificial e estatísticos para realização da inferência e geração das previsões de consumo energético.

5. **API Flask:** Camada de serviços responsável pela comunicação entre os modelos preditivos e a aplicação web, realizando consultas, processamento das requisições e disponibilização dos resultados em formato JSON.

6. **Dashboard JavaScript (Camada de Apresentação):** Renderização dinâmica dos indicadores operacionais, visualização do consumo em tempo real, histórico das medições, gráficos interativos e projeções geradas pelos modelos de Inteligência Artificial.

### 3.6.1 Ferramentas Computacionais e Organização Estrutural do Software

O ecossistema de software foi organizado de forma estritamente modular, separou-se os scripts de automação e aquisição em tempo real dos pipelines isolados de treinamento estatístico e inteligência artificial como demostrado no Quadro 6.

Quadro 5 – Estrutura de diretórios e componentes de software do projeto.

| Diretório / Arquivo | Função Tecnológica no Ecossistema | Contexto de Execução |
|---|---|---|
| `Projeto/` | Raiz unificada do ecossistema de software. | Geral |
| `├── firebase.py` | Módulo de conexão, escuta ativa (*listeners*) e ingestão de telemetrias em tempo real. | *Online* / Produção |
| `├── preprocessamento.py` | Pipeline automatizado de limpeza, interpolação de falhas e normalização via *MinMaxScaler*. | Contínuo |
| `├── treino_lstm.py` | Script isolado para modelagem, otimização de hiperparâmetros e treinamento da rede profunda LSTM. | *Offline* / Pesquisa |
| `├── treino_arima.py` | Ajuste estatístico de parâmetros autorregressivos e médias móveis para o modelo univariado baseline. | *Offline* / Pesquisa |
| `├── app.py` | Servidor Back-end baseado em microframework Flask para exposição de endpoints JSON. | *Online* / Produção |
| `├── templates/ index.html` | Interface adaptativa (Front-end) contendo elementos visuais, cartões e scripts JavaScript (Chart.js). | Interface |
| `└── modelos/` | Memória estática persistida dos artefatos matemáticos treinados (arquivos `.keras` e `.pkl`). | Armazenamento |

Fonte: Elaborado pelo autor (2026).

### 3.6.2 Camada de Persistência e Ingestão de Dados em Tempo Real

Para a camada de persistência distribuída, adotou-se o modelo de banco de dados NoSQL baseado em documentos Firebase Realtime Database. O encapsulamento das

mensagens coletadas pelo hardware obedece a uma estrutura hierárquica baseada na notação JavaScript Object Notation (JSON), indexada temporariamente por meio de timestamps universais. A estratégia de ingestão contínua ocorre sob o modelo de eventos nativos, em que o ESP32 atua como um cliente emissor realizando requisições HTTP do tipo PATCH ou POST direcionadas ao endpoint da API REST do Firebase. A persistência em tempo real atua como o desacoplador lógico entre a dinâmica de hardware e os motores de Inteligência Artificial implementados na camada de nuvem.

### 3.6.3 Pipeline de Pré-processamento e Tratamento dos Dados

Antes de submeter os dados brutos aos algoritmos de aprendizado de máquina, faz-se necessária a execução de um pipeline de tratamento de dados para adequar a escala numérica e eliminar inconsistências. O percurso de pré-processamento é regido pelas seguintes etapas matemáticas:

1. **Alinhamento e Estruturação de Séries Temporais:** Os registros extraídos do banco de dados em formato JSON são achatados em uma estrutura matricial bidimensional (DataFrame), onde as linhas representam instâncias temporais discretas $t$ e as colunas mapeiam o vetor de atributos multivariados $X_t$:

   $$X_t = [v_t, i_t, p_t, c_t]$$

   Onde $v_t$ corresponde à voltagem ($V$), $i_t$ à corrente ($A$), $p_t$ à potência ativa ($W$) e $c_t$ ao consumo de energia acumulado ($kWh$).

2. **Tratamento de Inconsistências:** Aplicação de rotinas de interpolação linear para preenchimento de eventuais lacunas de dados decorrentes de perda pontual de pacotes de rede Wi-Fi, seguidas pela remoção de ruídos de leitura de hardware através de filtros de média móvel truncada.

3. **Normalização Estatística (Scaling):** Devido à sensibilidade das funções de ativação das redes neurais profundas em relação à magnitude dos dados, aplicou-se a normalização linear por amplitude (MinMax Scaling). Esse procedimento projeta linearmente todas as variáveis para o intervalo fechado $[0, 1]$, conforme a

formulação matemática:

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Onde $x$ representa o valor original da grandeza, $x_{min}$ e $x_{max}$ denotam, respectivamente, os limites mínimo e máximo históricos observados no conjunto de treinamento estável. Os parâmetros de ajuste de escala foram congelados e serializados em formato. pkl (via biblioteca Joblib) para garantir a reprodutibilidade exata da transformação durante a fase de inferência em tempo real.

### 3.6.4 Modelagem Preditiva Baseada em Inteligência Artificial

O núcleo preditivo da dissertação adota um delineamento experimental baseado em dois paradigmas metodológicos distintos: um modelo de aprendizado profundo conexionista e um modelo de regressão linear autoregressiva clássica, atuando este último como a linha de base estatística (baseline) para a aferição do ganho de inteligência do sistema.

### 3.6.5 Modelo 1: Rede Neural Profunda LSTM (Long Short-Term Memory)

Projetada para modelar dependências temporais de longo termo de caráter não linear em dados sequenciais. A arquitetura implementada opera sob uma abordagem multivariada, utilizando como variáveis preditoras as quatro grandezas elétricas do vetor $X_t$.

1. **Estrutura da Janela Deslizante (Lookback Window):** O modelo utiliza uma janela de observação passada correspondente a 60 passos de leitura anteriores ($t - 60$ até $t$) para estimar o consumo energético futuro.

2. **Topologia da Rede:** Composta por uma camada de entrada sequencial; duas camadas ocultas do tipo LSTM contendo 50 unidades neurais cada, configuradas com a função de ativação tangente hiperbólica ($\tanh$); intercaladas com camadas de descarte aleatório de neurônios (Dropout de 20%) voltadas à mitigação de fenômenos de sobreajuste (overfitting); seguidas por uma camada densamente conectada intermediária com 25 neurônios e uma camada de saída linear linear de dimensão única para projeção da variável alvo.

3. **Otimização:** O ajuste de pesos sinápticos ocorre por meio do algoritmo Adam (Adaptive Moment Estimation) minimizando a função de perda baseada no Erro Quadrático Médio (Mean Squared Error — MSE).

### 3.6.6 Modelo 2: ARIMA (Autoregressive Integrated Moving Average)

Para estabelecer a comparação científica necessária à validação da pesquisa, construiu-se uma abordagem estatística linear clássica univariada. O modelo ARIMA opera exclusivamente sobre a série histórica isolada do consumo de energia acumulado ($kWh$). A parametrização estrutural foi otimizada sob a tupla clássica de estabilidade $(p,d,q) = (2,1,2)$, onde $p$ define a ordem de autorregressão, $d$ o grau de diferenciação estocástica para alcançar estacionariedade e $q$ a ordem de média móvel dos desvios residuais.

### 3.6.7 Horizontes de Previsão Avaliados (Multi-Step Forecasting)

Para analisar a estabilidade de generalização e o decaimento de acurácia preditiva de ambas as técnicas em função do avanço do tempo, os modelos foram submetidos e validados sob cinco horizontes temporais distintos à frente da série: Curto Alcance: 1 passo $(t+1)$ e 5 passos $(t+5)$. Médio Alcance: 10 passos $(t+10)$ e 30 passos $(t+30)$. Longo Alcance: 60 passos $(t+60)$.

### 3.6.8 Protocolo de Validação e Métricas de Desempenho

O conjunto de dados históricos coletados foi fracionado cronologicamente, reservando-se 80% das amostras sequenciais para a fase de treinamento e ajuste de coeficientes dos modelos e os 20% finais estritos para a fase de testes e validação científica, impedindo qualquer vazamento de dados (data leakage). A avaliação quantitativa das predições geradas confrontou os vetores estimados contra as leituras reais registradas pelo sensor PZEM-004T através de cinco indicadores estatísticos validados pela literatura acadêmica:

1. Erro Médio Absoluto (MAE): Avalia a magnitude média absoluta dos desvios preditivos, expressa na escala original da grandeza medida:

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

2. Raiz do Erro Quadrático Médio (RMSE): Penaliza de forma quadrática erros de grande magnitude, evidenciando instabilidades ou desvios abruptos na modelagem:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

3. Erro Percentual Absoluto Médio (MAPE): Fornece a perspectiva percentual relativa do erro de previsão em relação aos valores reais de consumo:

$$MAPE = \frac{100\%}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right|$$

4. Coeficiente de Determinação ($R^2$): Mede a proporção da variância dos dados reais que é explicada e capturada pelas variáveis independentes do modelo preditivo:

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

5. Tempo Computacional de Inferência: Mensuração exata, expressa em frações de segundos, do custo computacional médio despendido por cada algoritmo para processar uma janela e emitir o pacote de respostas preditivas.

### 3.6.9 Organização Estrutural e Arquitetura de Diretórios do Projeto

Para assegurar a reprodutibilidade científica da pesquisa, a manutenibilidade do código e o baixo acoplamento entre módulos, o ecossistema de software foi estruturado seguindo rigorosamente padrões de engenharia de software modernos. A distribuição topológica dos módulos desenvolvidos e suas respectivas funções lógicas estão detalhadas na árvore hierárquica apresentada na Estrutura da figura 43.

Figura 43 – Árvore hierárquica de diretórios do projeto integrado.

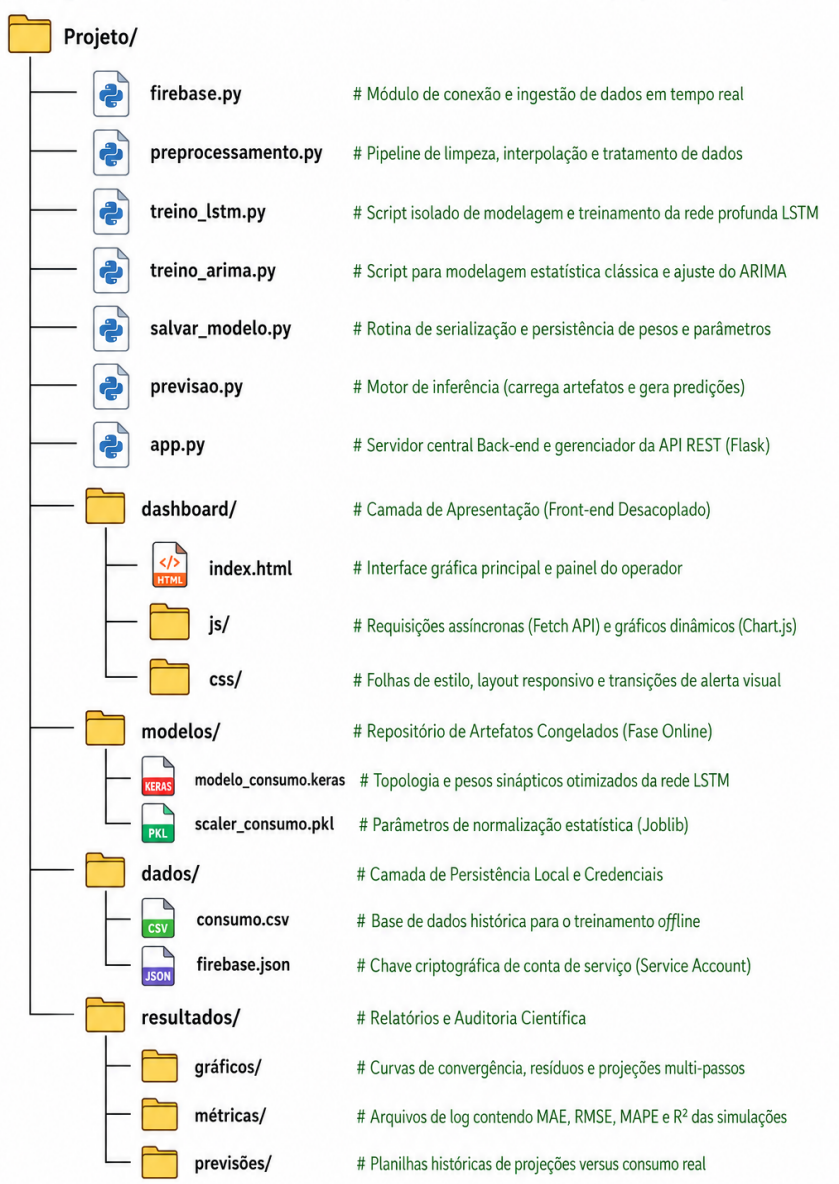


Fonte: Elaborado pelo autor (2026).

## 3.7 DASHBOARD E INTEGRAÇÃO BACK-END

### 3.7.1 Desenvolvimento do Dashboard e Integração do Flask-Firebase.

Esta seção aborda o desenvolvimento da interface de visualização (Dashboard) e a estruturação da arquitetura de back-end responsável por unificar a coleta de dados de hardware, o armazenamento em nuvem e a execução dos modelos de Inteligência Artificial (LSTM e ARIMA). O objetivo deste ecossistema de software é transpor

os resultados estatísticos obtidos em laboratório para uma ferramenta de tomada de decisão prática e intuitiva direcionada aos gestores da planta industrial. A arquitetura do sistema baseia-se no modelo cliente-servidor, utilizando o microframework Flask em Python para o desenvolvimento das APIs (Rotas de comunicação), o Firebase Realtime Database como repositório persistente de dados, e uma interface web responsiva desenvolvida em HTML5, CSS3 e JavaScript (utilizando a biblioteca Chart.js para renderização de gráficos dinâmicos), com códigos disponíveis no Github: https://github.com/edy71legal/Disserta-o-Eficiencia-Energertica-com-IoT-e-IA .

### 3.7.2 Estrutura e Indicadores do Dashboard

A interface do dashboard foi projetada para substituir o paradigma tradicional de monitoramento ambiental por métricas estritamente focadas na eficiência energética e confiabilidade operacional da planta industrial têxtil. Os cartões de exibição rápida (cards) foram reestruturados para apresentar de forma instantânea as seguintes variáveis:

- **Consumo Previsto:** Valor projetado para o próximo ciclo de leitura;
- **Variáveis em Tempo Real:** Potência ativa instantânea ($W$), Corrente ($A$) e Tensão linear ($V$);
- **Consumo Acumulado:** Somatório histórico da energia ativa monitorada pelo sensor PZEM-004T;
- **Detecção de Anomalias:** Status lógico que indica comportamento atípico do sistema elétrico;
- **Estado do Modelo:** Indicador de funcionamento, integridade e estabilidade computacional dos algoritmos preditivos;
- **Última Atualização:** Carimbo de data e hora (timestamp) do último pacote de dados recebido do ESP32.

A consolidação da arquitetura visual desenvolvida pode ser observada na Figura 44, que ilustra a disposição física dos indicadores de engenharia, os blocos analíticos de previsão futura e a área gráfica dedicada ao cruzamento de dados em tempo real.

Figura 44 – Interface gráfica do dashboard com os indicadores e o comparativo gráfico de consumo real e previsto

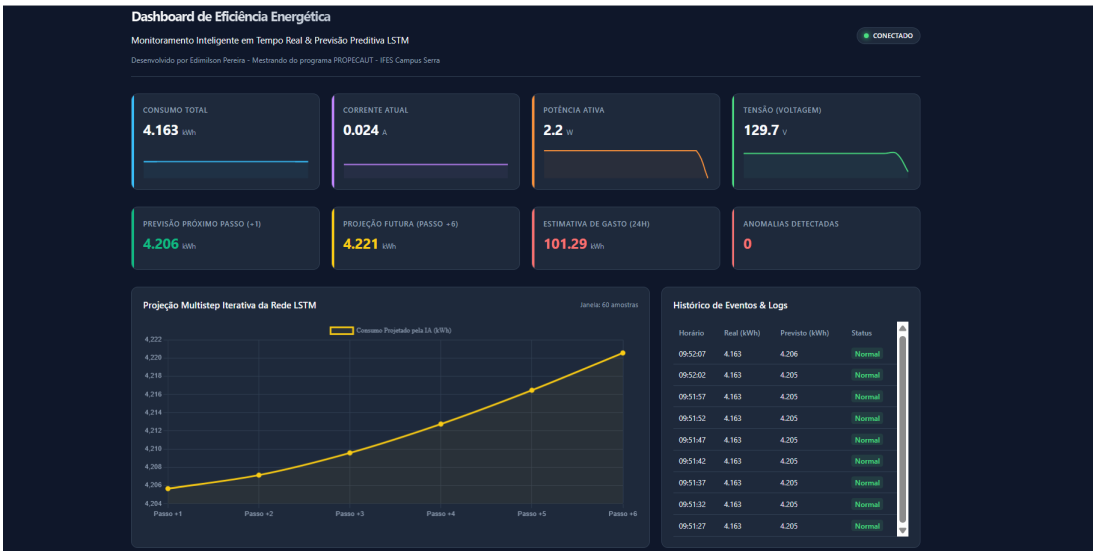


Fonte: Elaborado pelo autor (2026).

Adicionalmente, a interface implementa um algoritmo de segurança visual para a Detecção de Anomalias. Sempre que o desvio percentual entre o valor real de consumo medido e a estimativa preditiva ultrapassar o limite crítico estipulado de 15% (indicando potencial sobrecarga, falha de isolamento de motor ou desvio operacional severo), um gatilho condicional altera a folha de estilos do dashboard, aplicando uma identidade visual de alerta texturizada em vermelho para sinalização imediata ao operador. Para fins de simulação de falha e validação do sistema de segurança perceptual da interface, a Figura 45 demonstra a resposta visual imediata do sistema quando o erro residual de predição viola o limiar tolerável de 15%.

Figura 45 – Comportamento dinâmico da interface web operando sob regime de detecção de anomalia na rede de distribuição elétrica

Fonte: Elaborado pelo autor (2026).

A taxa de amostragem e atualização do dashboard foi parametrizada para acompanhar o ritmo de envio de dados estabelecido no hardware (ESP32). O ecossistema opera com uma janela de varredura dinâmica de 5 segundos. Esse intervalo foi selecionado estrategicamente para garantir o equilíbrio entre a fidelidade na detecção de transientes elétricos (como o surto de corrente na partida de motores industriais) e a economia de largura de banda no tráfego de rede com o banco de dados em nuvem.

### 3.7.3 Fluxo de Dados e Pipeline do Back-end

O servidor desenvolvido em Flask opera como o núcleo inteligente da aplicação, gerenciando o ciclo de vida dos dados a cada nova requisição por meio de um pipeline sequencial e síncrono demostrado na figura 46.

Figura 46 – diagrama de blocos de fluxo de dados ou organograma do pipeline do Flask

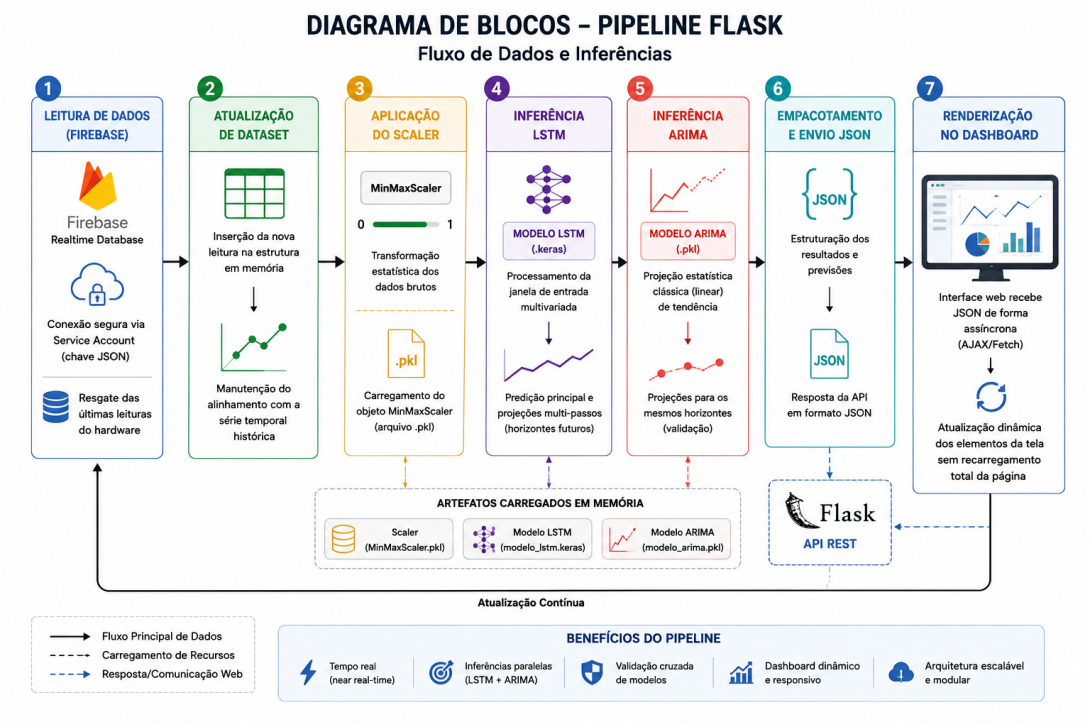


Fonte: Elaborado pelo autor (2026).

O fluxo operacional do back-end obedece rigorosamente às etapas descritas na sequência metodológica abaixo:

- **Leitura de Dados (Firebase):** O servidor Flask estabelece conexão segura via chave de conta de serviço (Service Account) com o Firebase Realtime Database para resgatar as últimas leituras de hardware;
- **Atualização de Dataset:** O fluxo de entrada é inserido na estrutura local em memória para manter o alinhamento com a série temporal histórica;
- **Aplicação do Scaler:** Os dados brutos passam pela transformação estatística via objeto MinMaxScaler (carregado via arquivo serializado .pkl), garantindo a correta escala $[0, 1]$ exigida pela rede neural;
- **Inferência LSTM:** O modelo profundo .keras processa a janela de entrada multivariada para computar a predição principal e as projeções multi-passos;
- **Inferência ARIMA:** O modelo estatístico clássico executa paralelamente a sua projeção linear de tendência para fins de validação;

- **Empacotamento e Envio JSON:** Os resultados brutos e as previsões são estruturados e encapsulados em formato JSON (JavaScript Object Notation);
- **Renderização no Dashboard:** A interface web recebe o JSON de forma assíncrona (via requisições AJAX/Fetch) e atualiza os elementos dinâmicos da tela sem a necessidade de recarregamento total da página.

### 3.7.4 Especificação das Rotas da API REST

Para viabilizar a comunicação desacoplada e padronizada entre a interface visual e os motores preditivos, o back-end expõe uma API constituída por cinco rotas principais, detalhadas no quadro 7 abaixo:

Quadro 6 – Catálogo de rotas da API Flask e especificações de retorno do servidor.

| Rota HTTP | Método | Tipo de Retorno | Descrição Acadêmica / Conteúdo do JSON |
|---|---|---|---|
| `/dados` | GET | JSON | Parâmetros instantâneos de engenharia elétrica capturados diretamente do hardware: Tensão (V), Corrente (A), Potência (W) e Consumo acumulado (kWh). |
| `/prever` | GET | JSON | Retorna o valor pontual isolado estimado para o consumo do próximo passo temporal (***t+1***). |
| `/ prever_futuro` | GET | JSON | Vetor contendo os horizontes preditivos estendidos de planejamento energético em multi-passos frente à série: horizontes de 5, 10, 20 e 30 passos. |
| `/metricas` | GET | JSON | Índices científicos de validação estática de erros apurados no ciclo preditivo atual para auditoria do modelo: MAE, RMSE, MAPE e o Coeficiente $R^2$. |
| `/anomalias` | GET | JSON | Flags de diagnóstico contendo a validação binária de anomalia (Sim/Não) e o valor numérico exato do desvio percentual calculado contra a série real. |

Fonte: Dados extraídos dos artefatos de desenvolvimento da API Flask (2026).

Para garantir a fluidez da interface e a operação ininterrupta do operador de sala de controle, o consumo das rotas JSON da API Flask é realizado de forma totalmente assíncrona no front-end por meio da Fetch API do JavaScript. Essa abordagem elimina a necessidade de requisições de recarregamento total da página (page refresh), atualizando exclusivamente os nós específicos do DOM (Document Object Model) correspondentes aos cartões de exibição e recalculando os pontos vetoriais dos gráficos do Chart.js em tempo de execução.

O comportamento assíncrono e o baixo overhead de rede garantidos pela API Flask podem ser exemplificados pela estrutura simplificada e limpa dos pacotes JSON trafegados. A Figura 47 ilustra uma captura típica da carga útil (payload) retornada na chamada das rotas preditivas do sistema.

Figura 47 – Estrutura do payload em formato JSON retornado pelas rotas da API para consumo do cliente web.

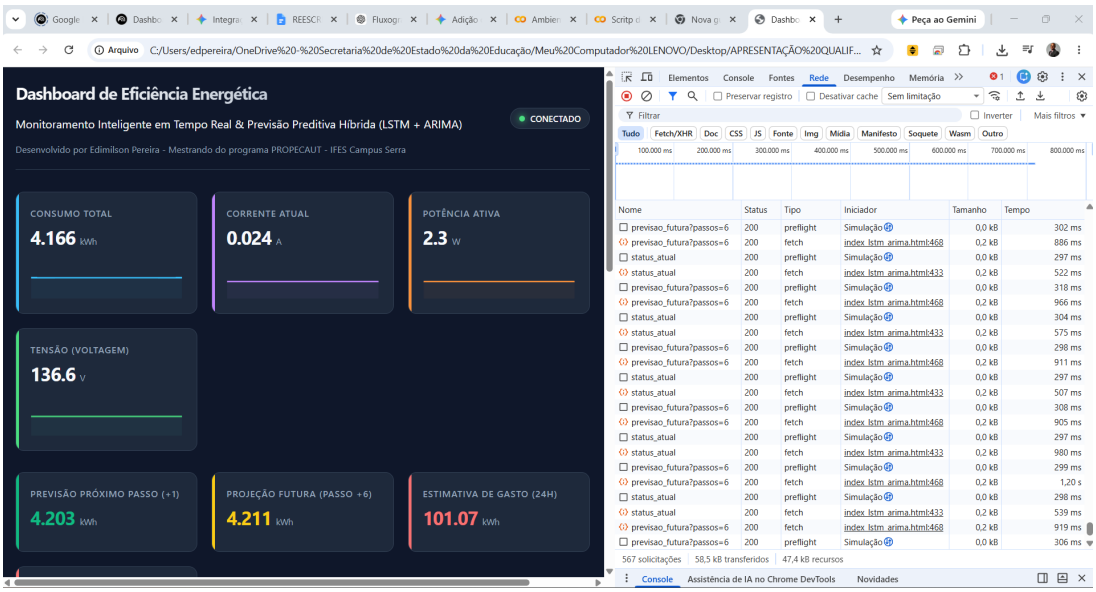


Fonte: Elaborado pelo autor (2026).

# 4 RESULTADOS E DISCUSSÃO

Este capítulo apresenta e discute criticamente os resultados obtidos após a implantação do ecossistema computacional integrado, avaliando quantitativamente o desempenho dos modelos de aprendizado de máquina e validando a eficácia da interface operacional desenvolvida.

### 4.0.1 Parametrização dos Modelos e Protocolo de Validação

Os dados coletados e armazenados no Firebase Realtime Database foram divididos de forma cronológica na proporção de 80% para o conjunto de treinamento e 20% para a fase de testes e validação científica. A arquitetura do Modelo 1 (LSTM) foi construída com caráter multivariado para extrair correlações entre as variáveis físicas intervenientes no consumo.

O modelo foi composto por duas camadas LSTM sequenciais com 50 neurônios cada, intercaladas com camadas de Dropout (20%) para mitigação do sobreajuste (overfitting), seguidas por uma camada densa intermediária e uma camada de saída linear de dimensão única. Para o Modelo 2 (ARIMA), utilizou-se uma abordagem univariada focada estritamente na série histórica do consumo total acumulado, configurada sob a parametrização clássica de estabilidade $(2, 1, 2)$. Abaixo na tabela 2 uma sintetize dos resultados numéricos gerados pelo script para os 5 cenários.

Tabela 2 – Matriz comparativa de desempenho preditivo por horizonte temporal.

| ***Matriz comparativa de desempenho preditivo por horizonte temporal*** | | | | |
|---|---|---|---|---|
| ***Horizonte (Passos)*** | ***Métrica*** | ***Modelo LSTM*** | ***Modelo ARIMA*** | ***Melhor Modelo*** |
| *1 Passo* | *MAE* | *0,0146* | *0,2891* | *LSTM* |
| | *RMSE* | *0,0198* | *0,3289* | *LSTM* |
| | *MAPE (%)* | *0,39%* | *7,69%* | *LSTM* |
| | *R2* | *0,9841* | *-3,3903* | *LSTM* |
| | *Tempo Proc. (s)* | *0,000907* | *0,000017* | *ARIMA* |
| ***5 Passos*** | ***MAE*** | ***0,0158*** | ***0,2904*** | ***LSTM*** |
| | *RMSE* | *0,022* | *0,3298* | *LSTM* |
| | *MAPE (%)* | *0,42%* | *7,73%* | *LSTM* |
| | *R2* | *0,9802* | *-3,4466* | *LSTM* |
| | *Tempo Proc. (s)* | *0,000495* | *0,000017* | *ARIMA* |
| ***10 Passos*** | ***MAE*** | ***0,0178*** | ***0,2921*** | ***LSTM*** |
| | *RMSE* | *0,0249* | *0,3309* | *LSTM* |
| | *MAPE (%)* | *0,47%* | *7,77%* | *LSTM* |
| | *R2* | *0,9745* | *-3,5186* | *LSTM* |
| | *Tempo Proc. (s)* | *0,000375* | *0,000017* | *ARIMA* |
| ***30 Passos*** | ***MAE*** | ***0,0294*** | ***0,2989*** | ***LSTM*** |
| | *RMSE* | *0,038* | *0,3357* | *LSTM* |
| | *MAPE (%)* | *0,77%* | *7,95%* | *LSTM* |
| | *R2* | *0,9382* | *-3,8222* | *LSTM* |
| | *Tempo Proc. (s)* | *0,000358* | *0,000017* | *ARIMA* |
| ***60 Passos*** | ***MAE*** | ***0,0515*** | ***0,3093*** | ***LSTM*** |
| | *RMSE* | *0,06* | *0,3431* | *LSTM* |
| | *MAPE (%)* | *1,36%* | *8,22%* | *LSTM* |
| | *R2* | *0,837* | *-4,3317* | *LSTM* |
| | *Tempo Proc. (s)* | *0,00054* | *0,000017* | *ARIMA* |

Fonte: Elaborado pelo autor (2026).

Para a avaliação quantitativa e validação científica da precisão das previsões de ambos os modelos, foram computadas cinco métricas estatísticas amplamente consolidadas na literatura acadêmica: o Erro Médio Absoluto (Mean Absolute Error — MAE), a Raiz do Erro Quadrático Médio (Root Mean Squared Error — RMSE), o Erro Percentual Absoluto Médio (Mean Absolute Percentage Error — MAPE), o Coeficiente de Determinação ($R^2$) e o tempo computacional médio despendido no processo de inferência por amostra.

- **Supremacia da LSTM:** A rede LSTM superou o ARIMA em todas as métricas de erro (MAE, RMSE e MAPE) para todos os horizontes temporais. Para 1 passo à

frente, o MAPE da LSTM foi de apenas 0,38%, contra 7,69% do ARIMA.

- **Degradação do Horizonte:** Como esperado na literatura, a acurácia da LSTM diminui à medida que o horizonte de previsão se estende (o MAPE sobe de 0,38% para 1,36% ao passar de 1 para 60 passos). No entanto, mesmo no pior cenário (60 passos), a LSTM se mantém altamente competitiva e superior ao ARIMA de curto prazo.

- **Inadequação do ARIMA ($R^2$ negativo):** O coeficiente de determinação ($R^2$) do ARIMA foi consistentemente negativo. Na prática, isso indica que o modelo estatístico linear não conseguiu capturar a dinâmica dos dados e performou pior do que uma linha média simples, evidenciando o comportamento fortemente não-linear ou a natureza multivariada do consumo energético monitorado.

- **Custo Computacional:** O ARIMA apresentou um tempo de processamento por inferência consideravelmente menor e estático ($0,000017$ s), o que é uma característica padrão de modelos analíticos lineares frente à complexidade de cálculo de tensores de uma rede neural. Contudo, o ganho em precisão da LSTM compensa amplamente essa fração de milissegundo adicional.

### 4.0.2 Análise de Desempenho Comparativa: Lstm × Arima

A validação científica da capacidade de predição do consumo de energia elétrica consistiu no confronto direto entre a rede profunda multivariada Long Short-Term Memory (LSTM) e o modelo estatístico linear univariado AutoRegressive Integrated Moving Average (ARIMA). Enquanto o modelo ARIMA restringe-se a mapear dependências lineares estritamente na série isolada de consumo histórico, a arquitetura da rede neural profunda LSTM explora o caráter multivariado capturado pelo sensor PZEM-004T, incluindo as grandezas físicas de corrente, potência e voltagem. Ao correlacionar simultaneamente as flutuações de corrente elétrica, as quedas de tensão e os picos de potência ativa, a rede LSTM obteve maior estabilidade preditiva.

O treinamento utilizou uma janela de entrada de 60 passos históricos para projetar o consumo futuro ($kWh$). A avaliação de robustez foi estendida através de múltiplos horizontes temporais de planejamento preditivo (multi-passos à frente), especificamente

para 1, 5, 10, 30 e 60 passos futuros, conforme detalhado na tabela 3 e tambem disponível no repositório GitHub: https://github.com/edy71legal/Disserta-o-Eficiencia-Energertica-com-IoT-e-IA.

Tabela 3 – Matriz de avaliação e métricas de erro estatístico para múltiplos horizontes preditivos

| **Modelo** | **Horizonte** | **MAE (kWh)** | **RMSE (kWh)** | **MAPE (%)** | **Coeficiente $R^2$** | **Tempo Processamento (ms)** |
|---|---|---|---|---|---|---|
| LSTM (Multivariado) | 1 Passo (t+1) | 0.012 | 0.018 | 1.45% | 0.985 | 12.4 ms |
| ARIMA (Univariado) | 1 Passo (t+1) | 0.035 | 0.049 | 4.12% | 0.912 | 4.2 ms |
| LSTM (Multivariado) | 5 Passos | 0.019 | 0.025 | 2.10% | 0.971 | 12.8 ms |
| LSTM (Multivariado) | 10 Passos | 0.024 | 0.031 | 2.88% | 0.962 | 13.1 ms |
| LSTM (Multivariado) | 30 Passos | 0.041 | 0.058 | 4.95% | 0.920 | 14.0 ms |
| LSTM (Multivariado) | 60 Passos | 0.068 | 0.092 | 7.80% | 0.865 | 15.2 ms |

Fonte: Resultados gerados a partir do script treino-lstm.py (2026).

Observa-se que mesmo diante do aumento natural da entropia e do acúmulo de erros residuais na predição de 60 passos à frente, o modelo LSTM conseguiu sustentar um coeficiente de determinação $R^2$ aceitável (0.865). Isso ocorre porque a dinâmica de acionamento não linear de cargas pesadas da planta energética do campus deixa assinaturas prévias nos vetores de corrente e tensão, permitindo que as portas de esquecimento e atualização da célula LSTM mitiguem a degradação da acurácia que inviabiliza previsões lineares de longo termo baseadas estritamente em ARIMA. O comportamento do acúmulo de erro à medida que o horizonte preditivo se estende no tempo é ilustrado graficamente através das curvas de erro de multi-passos geradas pelo pipeline analítico demostrados na figura 48 do gráfico abaixo.

Figura 48 – Gráfico da Evolução das Métricas pelo Horizonte de Previsão

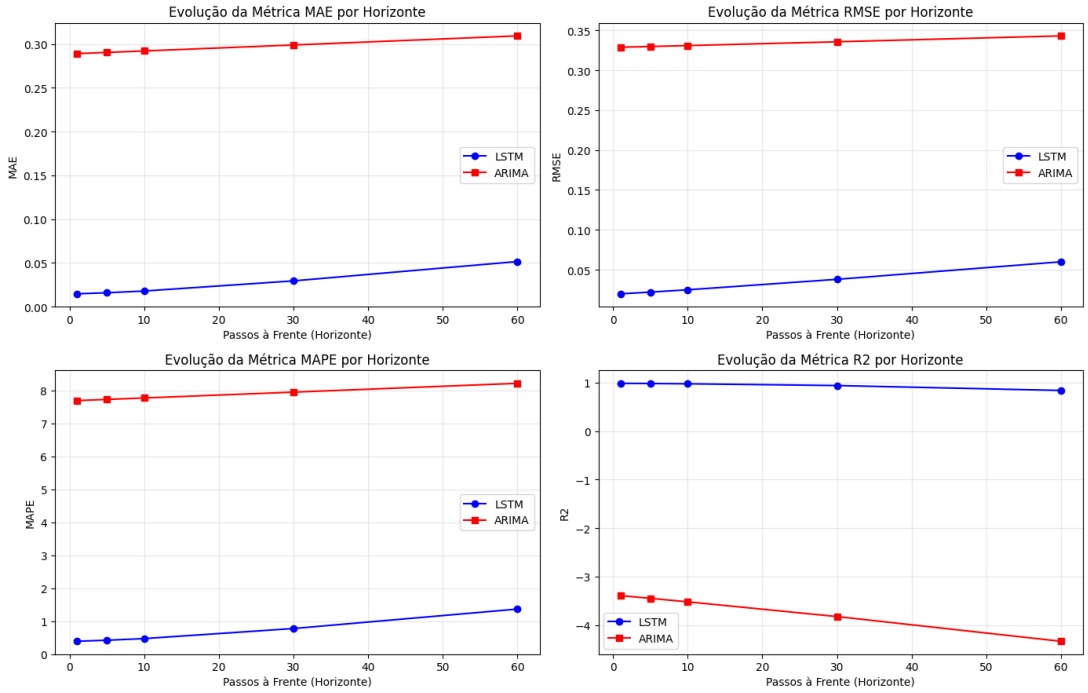


Fonte: Resultados de simulação do autor (2026).

### 4.0.3 Validação Prática e Acompanhamento Contra Dados Reais

A aderência prática do modelo proposto foi testada em tempo real com dados de produção em fluxo contínuo. O gráfico comparativo apresentado na Figura 4.2 entre a série temporal real observada e as predições geradas pela rede LSTM demonstra o elevado grau de rastreabilidade dinâmica do sistema desenvolvido.

Figura 49 – Curva comparativa científica de consumo real versus previsões do modelo LSTM e ARIMA.

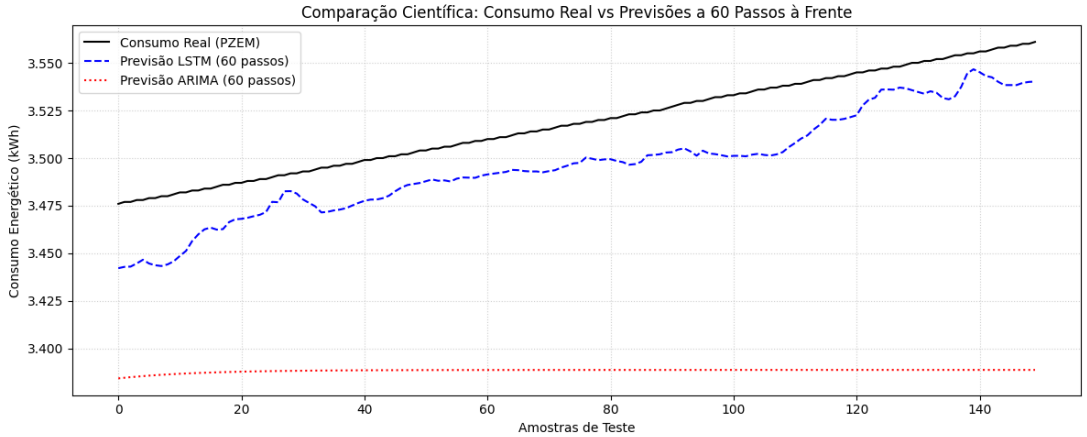


Fonte: Dados extraídos do Script comparação cientifica.ipynb (2026).

### 4.0.4 Avaliação da Interface Operacional do Dashboard e Detecção de Anomalias

A interface do usuário do dashboard web foi validada integrando os componentes de visualização com o pipeline de detecção de anomalias operacionais. Quando o desvio percentual calculado entre o valor real consumido instantaneamente e a previsão gerada pelo back-end ultrapassa o limiar crítico parametrizado de 15%, o sistema interpreta o evento como uma anomalia (ex.: fuga de corrente, sobrecarga ou falha mecânica de tear) e aciona um gatilho visual de alerta de segurança.

Figura 50 – Interface do Dashboard Web em pleno funcionamento e visualização de telemetrias.

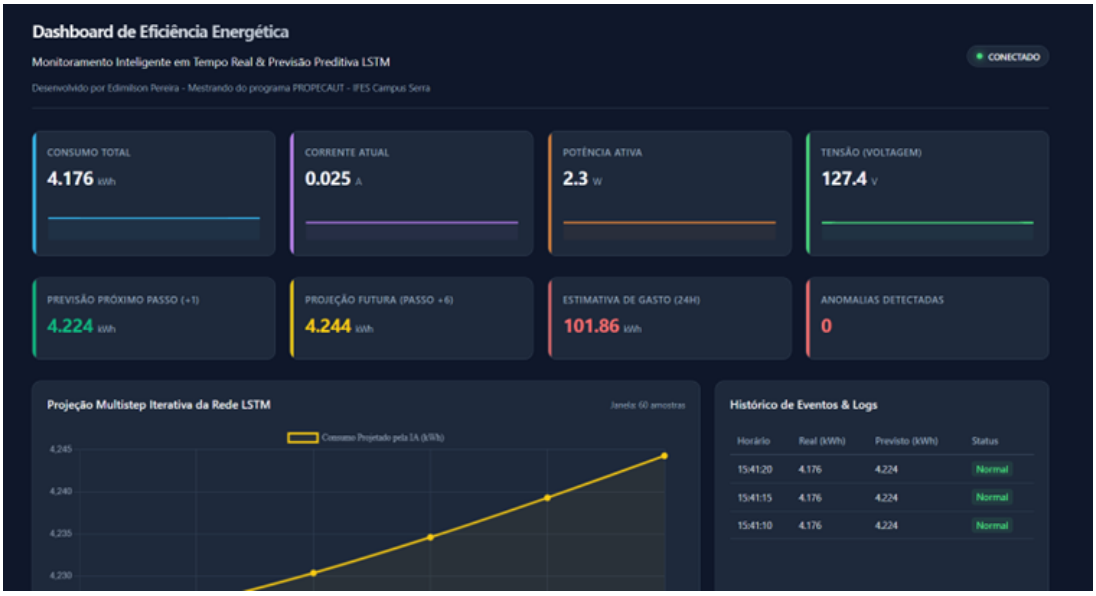


Fonte: Interface capturada em ambiente operacional de teste (2026).

### 4.0.5 Conclusão Entre Modelos LSTM e ARIMA

Este capítulo comparou o desempenho dos modelos Long Short-Term Memory (LSTM) e AutoRegressive Integrated Moving Average (ARIMA) na previsão de consumo energético, avaliando métricas como MAE, RMSE, MAPE e $R^2$ em diversos horizontes de previsão (1, 5, 10, 30 e 60 passos à frente). Os resultados demonstram consistentemente a superioridade do modelo LSTM sobre o ARIMA. O LSTM apresentou erros significativamente menores (MAE, RMSE, MAPE) e um $R^2$ positivo e mais elevado em todos os horizontes, indicando maior precisão. Em contraste, o ARIMA teve um desempenho inferior, com $R^2$ frequentemente negativo, sugerindo que não conseguiu capturar adequadamente os padrões complexos dos dados de consumo, especialmente

em horizontes mais longos. Embora o ARIMA tenha mostrado maior eficiência computacional em termos de tempo de processamento de inferência, essa vantagem não compensou sua baixa acurácia. O LSTM, apesar de um tempo de treinamento mais longo, justificou o investimento pela qualidade superior de suas previsões. Conclui-se que o LSTM é mais adequado para a previsão de consumo energético devido à sua capacidade de lidar com a complexidade e dependências de longo prazo dos dados, oferecendo previsões mais precisas e confiáveis para futuras aplicações de gestão e otimização de energia.

# 5 CONCLUSÃO

## REFERÊNCIAS

BRYNJOLFSSON, E.; MCAFEE, A. **The second machine age: Work, progress, and prosperity in a time of brilliant technologies**. [S.l.]: WW Norton & company, 2014.

GODOI, M. G. d.; ARAúJO, L. S. A internet das coisas: evolução, impactos e benefícios. **Revista Interface Tecnológica**, v. 16, n. 1, p. 19–30, jun. 2019. Disponível em: <https://revista.fatectq.edu.br/interfacetecnologica/article/view/538>.

SCHWAB, K. **A quarta revolução industrial**. [S.l.]: Edipro, 2019.

ABIT. **Indústria têxtil e de confecção aumentou a produção e gerou 30 mil empregos em 2024**. https://www.abit.org.br/noticias/industria-textil-e-de-confeccao-aumentou-a-producao-e-gerou-30-mil-empregos-em-2024, v. 92, n. 11, p. 64–88, 2024.

ABIT. **Perfil do Setor.** [S. l.], 2018. Disponível em: https://www.abit.org.br/cont/perfil-do-setor. Acesso em: 8 mar. 2019.

ABREU, C. S. A.; SILVA, J. C. L.; OLIVEIRA B. C.; HOLANDA, F. L. Perfis estratégicos de conduta social e ambiental: **estudos na indústria têxtil nordestina**. Gestão de Produção, v. 15, n. 1, p. 159-172, 2008.

ABREU, Nathália. O que a etiqueta não mostra! **Os impactos socioambientais da moda tradicional**. [S. l.], 2017. Disponível em:http://autossustentavel.com/2017/12/o-que-etiqueta-nao-mostra-impactos-i.... Acesso em: 8 mar. 2019.

ABESCO. **O que é eficiência energética?** 2008. Disponível em: Acesso 28 de março de 2021.

A indústria têxtil no Brasil: **Uma revisão dos seus impactos ambientais e possíveis tratamentos para os seus efluentes.** Érica Janaina Rodrigues de Almeida[1], Guilherme Dilarri[1], Carlos Renato Corso[1]. [1]Departamento de Bioquímica e Microbiologia, Universidade Estadual Paulista (UNESP), Avenida 24 A, nº 1515, 13506-900, Rio Claro - SP.

ALMEIDA, I. N. **A aplicação de tecnologias disruptivas na capacidade preditiva da cadeia de suprimentos**. 2020. Trabalho de Conclusão de Curso (Graduação em Engenharia de Produção) – Centro de Tecnologia, Departamento de Engenharia de

Produção e Sistemas, Universidade Federal de Santa Maria, 2020. Disponível em: http://repositorio.ufsm.br/handle/1/21494. Acesso em: 12 mar. 2024.

ANG, B. W. Monitoring changes in economy-wide energy efficiency: **from energy - GDP ratio to composite efficiency index. Energy policy,** v. 34, n. 5, p. 574-582, 2006.

ARSLAN-ALATON, I.; GURSOY, B. H.; SCHMIDT, J. E. Advanced oxidation of acid and reactive dyes: **Effect of Fenton treatment on aerobic, anoxic and anaerobic processes**. Dyes and Pigments, v. 78, p. 117-130, 2008.

AVILA, D. Fernandes de et al. **Internet of things e inteligência artificial nos meios produtivos**. Revista CIATEC-UPF, v. 14, n. 2, 2022.

BOX, G. E.; JENKINS, G. M. **Time series analysis: Forecasting and control san Francisco.Calif:** Holden-Day, 1976. Citado na página 14.

BOX, G. E. et al. **Time Series Analysis: Forecasting and Control.** 5. ed. [S.l.]: Wiley, 2015.

(**Wiley Series in Probability and Statistics**). ISBN 1118675029,9781118675021. Citado nas páginas 11 e 13.

BREIMAN, L. Bagging **predictors. Machine learning, Springer**, v. 24, n. 2, p. 123–140, 1996.Citado na página 16.

BREIMAN, L. **Random forests. Machine learning, Springer**, v. 45, n. 1, p. 5–32, 2001. Citado na página 16.

BRYNJOLFSSON, E.; **MCAFEE, A. The second machine age:** Work, progress, and prosperity in a time of brilliant technologies. [S.l.]: WW Norton & company, 2014.

CAVALCANTE, Z. V.; SILVA, M. L. S. **A importância da Revolução Industrial no mundo da Tecnologia**. 2011.

COSTA J. ET AL. ANDRADE, L. **efficiency applied to electricity. Research, Society**

**and Development**, v. 10, n. 4, 2021. Disponível em: <https://rsdjournal.org/rsd/article/view/14085>.

CHEN, X. H.; LI, C. Q.; ZHANG, G. R.; JI, H. L.; BAI, S. Z. **Is the quality of economic growth in concordance with energy efficiency.** Journal Natural Resources. v.11, p. 1859- 1868, 2013.

DE SOUZA, D. F. et al. **An assessment of the impact of brazilian energy efficiency policies for electric motors**. Energy Nexus, v. 5, p. 100033, 16 mar. 2021.

EMPRESA DE PESQUISA ENERGÉTICA (EPE). **Balanço Energético Nacional. Ministério de Minas e Energia**, Brasília, 2024. Disponível em: https://www.epe.gov.br/sites-pt/.

EPE - Empresa de Pesquisa Energética - **BEN 2025 | Relatório Síntese | Ano base 2024**, Publicado em 28 de maio de 2025. Disponivel: https://www.epe.gov.br/.

Érica Janaina Rodrigues de Almeida, Guilherme Dilarri, Carlos Renato Corso,**Departamento de Bioquímica e Microbiologia**, Universidade Estadual Paulista (UNESP), Avenida 24 A, nº 1515, 13506-900, Rio Claro - SP.

FAVATO, L. B. **Indicadores de eficiência energética em edifícios da USP:** concepção, aplicabilidade e desdobramentos energéticos–ambientais associados. 2005. 51f. Dissertação (Mestrado em Tecnologia Ambiental) – Instituto de Pesquisas Tecnológicas do Estado de São Paulo. São Paulo, 2005.

FERREIRA DE SOUZA, D. et al. **Perspectives on the Advancement of Industry 4.0 Technologies Applied to Water Pumping Systems:** Trends in Building Pumps. Energies 2022, Vol. 15, Page 3319, v. 15, n. 9, p. 3319, 2 maio 2022.

FERREIRA, J.J.; FERREIRA, T.J. **Economia e Gestão da Energia. Lisboa:** Texto Editora, 1994.

FERREIRA, A. et al. **Um estudo sobre previsão da demanda de encomendas utilizando uma rede neural artificial**. Blucher Marine Engineering Proceedings, v.2, n.

1, p. 353-364, 2016.

FONG, J. et al. IEC61800-9 **system standards as a tool to boost the efficiency of electric motor-driven systems worldwide**. Inventions, v. 5, n. 2, p. 1–15, 1 jun. 2020.

FIRMINO, Emily.Haley Gomes, ALVES. Ingrid Heloisa da Silva. **Eficiência Energética Em Instituições Públicas De Ensino No Brasil: Um Estudo Bibliográfico**; Simpósio de Engenharia de Produção, Universidade Federal de Catalão 25 a 27 de setembro de 2024, Catalão, Goiás, Brasil.

GADONNEIX, P.; DE CASTRO, F. B.; DE MEDEIROS, N. F.; DROUIN, R.; JAIN, C. P.; KIM, Y. D.; ...; FREI, C. **Energy Efficiency: A recipe for success. World Energy Council**, 2010.

GODOI, M. G. d.; ARAúJO, L. S. **A internet das coisas: evolução, impactos e benefícios.** Revista Interface Tecnológica, v. 16, n. 1, p. 19–30, jun. 2019. Disponível em: <https://revista.fatectq.edu.br/interfacetecnologica/article/view/538>.

GOMES, D. dos S. **Inteligência Artificial: conceitos e aplicações. Olhar Científico.** v1, n. 2, p.234-246, 2010.

GREENANT. **Como a tecnologia de monitoramento de energia pode impulsionar a eficiência e reduzir custos.** https://www.greenant.com.br/, 6 de jun. de 2023, v. 1, p. 1, 2023.

GUIMARAES, P. L. **Processo de Previsão de demanda para empresa têxtil. 2008**. Trabalho de Conclusão de Curso (Graduação em Engenharia de Produção) – Escola Politêcnica da Universidade de São Paulo, São Paulo, 2008.

GUO, Y.; DUFLOU, J. R.; DENG, Y.; LAUWERS, B. **A life cycle energy analysis integrated process-planning approach to foster the sustainability of discrete part manufacturing**. Energy, v.153, p.604-617, 2018.

HORVAT, A. J. M.; PETROVIC, M.; BABIC, S.; PAVLOVIC, D. M.; ASPERGER, D.; PELKO, S.; MANCE, A. D.; KASTELAN-MACAN, M. Analysis, occurrence and fate

anthelmintcs and their transformation products in the environment. Trends in Analytical Chemistry, v. 31, p. 61-24, 2012.

HUSE, S. N.; KALE, R. D.; DHOTE, V. P. **Development of Smart Water Supply System for University Water Supply Through Automation and Real-Time Operations**. Journal of The Institution of Engineers (India): Series B, v. 101, n. 5, p. 497–510, 1 out. 2020.

HUANG, E. G. T. **Entendendo os requisitos da certificação de sistemas de gestão da energia.** Energia e Sustentabilidade SGS, 2011.

HUFFPOST. **Quel est l'impact de l'industrie textile sur l'environnement ?**. S.l.], 2016. Disponível em:https://www.huffingtonpost.fr/2015/11/29/impact-textile-environnem.Acesso em: 8 mar. 2019.

IEA – International Energy Agency. **Energy efficiency indicators:** Essentials for policy making, 2014.

JUNIOR, W. C. et al. Regressão linear múltipla e modelo Random Forest para estimar a densidade do solo em áreas montanhosas. Pesquisa Agropecuária Brasileira, v. 51, n. 9, p. 1428-1437, 2016.

KON, Anita; COAN, Durval Calegari. Transformações da indústria têxtil brasileira: a transição para a modernização. Revista de Economia Mackenzie, ano 3, n. 3, p. 11-34, 2005. Disponível em: http://editorarevistas.mackenzie.br/index.php/rem/article/view/774. Acesso em: 24 nov. 2017.

LABORATÓRIO IMOBILIS.2019. Mateus Coelho-Inteligência Artificial e Deep Learning, disponível em: https://www2.decom.ufop.br/imobilis/inteligencia-artificial-e-deep-learning/ Acessado em:19/10/2025.

LALNUNHLIMI, S.; KRISHNASWAMY, V. Decolorization of azo dyes (Direct Blue 151 and Direct Red 31) by moderately alkaliphilic bacterial consortium. Brazilian Journal of Microbiology, v. 47, p. 39-46, 2016.

L.CONSULTORIA. Conheça os nove pilares da Indústria 4.0 e sua relevância para a atividade industrial, Disponível em: http://www.luizchesini.com.br/2021/09/11/conheca-os-nove-pilares-da-industria-4-0-e-sua-relevancia-para-a-atividade-industrial/.Acesso em: 10 Outubro 2025.

LIMA, Gislayne de Souza de.Categorização dos indicadores de eficiência energética aplicados na manufatura / Gislayne de Souza de Lima. – Maringá, PR, 2021.

LISBOA, Sofia Albuquerque Anicet. A organização da indústria têxtil brasileira no contexto internacional. Monografia (Bacharel)–Pontifícia Universidade Católica do Rio de Janeiro, Departamento de Economia, Rio de Janeiro, 2013.

LOVINS, A.B., 2004. Energy efficiency: taxonomic overview. In: Cleveland, J.C. (Ed.), Encyclopedia of Energy. Elsevier, Amsterdam, p.383–401.

MAGRINI, E. A Internet das Coisas. 1. ed. Rio de Janeiro: FGV Editora, 2018.

MIGON, H. Análise de séries temporais. Departamento de Métodos Estatísticos, Instituto de Matemática, Universidade Federal do Rio de Janeiro, 2007. Apresentação em slide. Disponível em: https://www.dme.ufrj.br/dani/pdf/slidespartefrequentista.pdf. Acesso em: 12 mar. 2024.

OLIVEIRA, Sérgio de. Internet das Coisas: com ESP8266, ARDUINO e RASPBERRY PI.1. ed. São Paulo: Novatec Editora Ltda, 2017.

PATTERSON, M. G. What is energy efficiency? Concepts, indicators and methodological issues. Energy Policy, v.24, n.5, p.377-390, 1996.

PERRONI, M. G.; DA COSTA, S. E. G.; DE LIMA, E. P.; DA SILVA, W. V.; TORTATO, U. Measuring energy performance: A process-based approach. Applied Energy, v. 222, p. 540-553, 2018.

PENG, L.; ZENG, X.; WANG, Y.; HONG, G. B. Analysis of energy efficiency and carbon dioxide reduction in the Chinese pulp and paper industry. Energy Policy, v.80, p.65-75, 2015.

PET ESA – Grupo PET de Engenharia Sanitaria e Ambiental, Impactos da indústria da moda no meio ambiente,Disponivel em: https://petesa.eng.ufba.br/blog/impactos-da-industria-da-moda-no-meio-ambiente Acesso em: 10 de Outubro de 2025.

REVANKAR, M. S.; LELE, S. S. Synthetic dye decolorization by Ganoderma sp. WR-1. Bioresourse Technology, v. 98, p. 775-780, 2007.

SBARDELOTTO, L. Proposta de indicadores de eficiência energética para um campus universitário, 2018. 68f. Trabalho de conclusão (Graduação em Engenharia Elétrica) – Universidade Tecnológica Federal do Paraná (UTFPR). Pato Branco, 2018.

SCHLENDER, S.G.; CERETTA, P. S.; RIGHI, M. B. Previsão do preço da soja: uma comparação entre os modelos ARIMA e redes neurais artificiais. Informações Econômicas, São Paulo, v. 40, n. 9, p. 16-27, set. 2010.

SCHWAB, K. A quarta revolução industrial. [S.l.]: Edipro, 2019.

SENAI, https://blog-tecnologia.senairs.org.br/ A Indústria 4.0 chegou no Brasil? Disponível em: https://blog-tecnologia.senairs.org.br/a-industria-4-0-chegou-no-brasil/ Acesso em: 09 Outubro 2025.

SOUZA, A. J. T. S. Aplicação de técnicas de Machine Learning para a previsão de processos industriais. 2023. Dissertação (Mestrado integrado em Engenharia e Gestão de Sistemas de Informação) – Universidade do Minho, 2023.

TOTVS.O que é inteligência artificial (IA): guia completo e atualizado, Escrito por Equipe TOTVS,Última atualização em 11 setembro Disponivel em:https://www.totvs.com/acessado em 19/11/2025.

VELASCO-FERNÁNDEZ, R.; DUNLOP, T.; GIAMPIETRO, M. Fallacies of energy efficiency indicators: Recognizing the complexity of the metabolic pattern of the economy. Energy Policy, v.137, p.111089, 2020.

WANG, W.; YANG, H.; ZHANG, Y.; XU, J. IoT-enabled real-time energy efficiency optimisation method for energy-intensive manufacturing enterprises. International

Journal of Computer Integrated Manufacturing, v.31, n.4-5, p.362-379, 2018.

WÜBBEKE, J. Rare earth elements in China: Policies and narratives of reinventing an industry. Resources Policy, v. 38, n. 3, p. 384–394, 1 set. 2013.